

Cuestionario: Ingesta de Datos y Expresiones Regulares

Total de puntos 90/100

Este cuestionario ha sido diseñado para evaluar tu dominio técnico en dos de los pilares fundamentales de la ingeniería de datos: la **captura eficiente de información** y la **manipulación precisa de cadenas de texto**.

El correo electrónico del destinatario (**leandrosebastiantrncoso@gmail.com**) se registró al enviar el formulario.

✓ ¿Qué característica principal define a los datos "No Estructurados"? * 5/5

- ☐ Tienen un esquema fijo de filas y columnas.
- ☒ Carecen de un formato nativo o estructura interna identificable de forma sencilla. ✓
- ☐ Se almacenan exclusivamente en bases de datos relacionales (SQL).
- ☐ Son archivos que solo contienen números enteros.

✓ En un pipeline de Ciencia de Datos, ¿cuál es el objetivo de la etapa de "Ingesta"? *5/5

- ☐ Entrenar modelos de Deep Learning.
- ☒ Obtener datos de diversas fuentes y ponerlos a disposición para su procesamiento. ✓
- ☐ Crear visualizaciones interactivas para el cliente.
- ☐ Eliminar permanentemente todos los registros que contengan errores.



✗ ¿Por qué el formato Apache Parquet es considerado un estándar de industria para Big Data? *0/5

- ☒ Porque es un formato de texto plano legible por humanos como el CSV. ✗
- ☐ Porque es el único formato que permite guardar imágenes dentro de tablas.
- ☐ Porque no requiere el uso de Python para ser leído.
- ☐ Porque utiliza almacenamiento basado en columnas, lo que permite una compresión y consulta eficiente.

✓ Si intentas abrir un archivo con caracteres como "ñ" o "á" y obtienes un error, ¿cuál es probablemente el problema? *5/5

- ☒ Hay un error de codificación (Encoding), como intentar leer UTF-8 como Latin-1. ✓
- ☐ El archivo está vacío.
- ☐ El nombre del archivo es demasiado largo.
- ☐ El archivo tiene demasiadas columnas.

✓ En Expresiones Regulares (Regex), ¿qué representa el símbolo \d? * 5/5

- ☐ Cualquier carácter que sea una letra minúscula.
- ☒ Cualquier dígito numérico del 0 al 9. ✓
- ☐ El inicio de una nueva línea de texto.
- ☐ Un espacio en blanco o tabulación.



✓ ¿Qué función de la librería re de Python usarías para reemplazar caracteres no deseados en un string?

*5/5

- ☐ re.findall()
- ☐ re.search()
- ☒ re.sub()
- ☐ re.split()



✓ ¿Qué significa el cuantificador + en una expresión regular (ejemplo: \d+)? * 5/5

- ☐ Que el elemento anterior aparece exactamente una vez.
- ☐ Que el elemento anterior aparece cero o más veces.
- ☒ Que el elemento anterior aparece una o más veces.
- ☐ Que el elemento anterior es opcional.



✓ Si tienes el string "Tel: 351-123-4567" y quieres extraer solo los números, *5/5
¿cuál sería el patrón Regex más simple?

- ☐ [a-z]
- ☒ \d+
- ☐ \s+
- ☐ ^Tel



✓ ¿Cuál es la principal desventaja de usar archivos CSV para datasets de gran escala (varios GB)? *5/5

- ☐ No se pueden abrir en Excel.
- ☐ Son archivos binarios difíciles de comprimir.
- ☒ La lectura es lenta porque el sistema debe parsear cada fila como texto plano. ✓
- ☐ No permiten guardar números decimales.

✓ ¿Qué hace el patrón `[\d]` en una operación de limpieza? * 5/5

- ☐ Busca cualquier dígito numérico.
- ☒ Busca cualquier carácter que NO sea un dígito numérico. ✓
- ☐ Busca solo espacios en blanco.
- ☐ Valida que el string comience con un número.

✓ Al procesar un archivo de texto libre, ¿qué técnica es mejor para separar campos con delimitadores inconsistentes (comas, pipes, puntos)? *5/5

- ☐ Usar el método `.split(",")` exclusivamente.
- ☒ Usar `re.split()` con un patrón que incluya todos los posibles delimitadores. ✓
- ☐ Borrar manualmente los delimitadores antes de cargar el archivo.
- ☐ Convertir el archivo a PDF primero.



✓ ¿Cuál es el propósito del módulo logging durante la ingesta de archivos? * 5/5

- ☐ Acelerar la velocidad de descarga de los datos.
- ☒ Registrar eventos, advertencias y errores de forma persistente para auditoría. ✓
- ☐ Dibujar gráficos de barras sobre los errores encontrados.
- ☐ Encriptar el archivo de salida para que nadie lo vea.

✓ En Regex, ¿qué representan los símbolos ^ y \$? * 5/5

- ☐ Suma y resta de caracteres.
- ☒ El inicio y el final de una línea o string, respectivamente. ✓
- ☐ Comienzo y fin de un comentario en el código.
- ☐ La presencia de símbolos de moneda en el texto.

✗ ¿Qué estrategia de "Gestión de Errores" es más drástica ante un dato faltante? *0/5

- ☒ Imputación (llenar con la media). ✗
- ☐ Flagging (marcar que falta el dato en una columna nueva).
- ☐ Ignorar el error y continuar sin hacer nada.
- ☐ Eliminación (Drop) del registro completo.



✓ ¿Qué formato de archivo es jerárquico y se usa comúnmente para el intercambio de datos en APIs web? *5/5

- ☐ CSV
- ☒ JSON
- ☐ TXT
- ☐ SQL



✓ ¿Para qué se utilizan los corchetes [] en una expresión regular? * 5/5

- ☐ Para definir un grupo de captura.
- ☒ Para definir un conjunto de caracteres permitidos (clase de caracteres).
- ☐ Para indicar que un patrón es opcional.
- ☐ Para realizar operaciones matemáticas.



✓ Si un registro tiene el nombre " juan perez ", ¿qué combinación de métodos de Python lo dejaría como "Juan Perez"? *5/5

- ☐ .upper().strip()
- ☒ .strip().title()
- ☐ .lower().replace(" ", "")
- ☐ .split().join()



✓ ¿Qué sucede si aplicas `re.findall()` y el patrón no encuentra ninguna coincidencia? *5/5

- ☐ El programa lanza un error `SyntaxError`.
- ☐ Devuelve un valor `None`.
- ☒ Devuelve una lista vacía `[]`.
- ☐ Se detiene la ejecución del script.



✓ Al utilizar la clase `csv.DictWriter` para guardar datos, ¿cuál es la función del parámetro `fieldnames`? *5/5

- ☐ Define el nombre del archivo físico que se creará en el disco.
- ☒ Define el orden y los nombres de las columnas que actuarán como cabecera del CSV.
- ☐ Indica cuántas filas de datos se van a escribir en total.
- ☐ Sirve para cifrar el contenido del archivo con una contraseña.



✓ En Regex, ¿cuál es la diferencia entre `\d{3}` y `\d*`? * 5/5

- ☐ No hay diferencia, ambos buscan números.
- ☒ `\d{3}` busca exactamente 3 dígitos; `\d*` busca cero o más dígitos.
- ☐ `\d{3}` busca al menos 3 dígitos; `\d*` busca solo un dígito.
- ☐ `\d{3}` es para teléfonos; `\d*` es para documentos de identidad.



El formulario se creó en Universidad de La Punta. - [Comunicarse con el propietario del formulario](#)

¿El formulario parece sospechoso? [Informe](#)



Google Formularios

