

SQL aplicado a la Ingeniería de Datos

Total de puntos 90/100

Cuestionario teórico-práctico sobre el uso de SQL aplicado a procesos de Data Science.

El correo electrónico del destinatario (leandrosebastiantrncoso@gmail.com) se registró al enviar el formulario.

✓ ¿Cuál es la función principal de SQL en el flujo de trabajo de Machine Learning según el material? *5/5

- ☒ Preparar y extraer datos antes del análisis y modelado. ✓
- ☐ Visualizar resultados finales mediante gráficos de dispersión.
- ☐ Diseñar la arquitectura de hardware del servidor de base de datos.
- ☐ Entrenar modelos de aprendizaje supervisado directamente en el servidor.

✓ ¿Cuál es la diferencia fundamental en cuanto al lugar de procesamiento entre SQL y Pandas? *5/5

- ☐ No existe diferencia; ámbos dependen exclusivamente de la capacidad de la memoria RAM local.
- ☐ Pandas procesa en la nube de forma nativa mientras que SQL es estrictamente local.
- ☐ SQL utiliza la GPU para cálculos masivos y Pandas sólo la CPU.
- ☒ SQL procesa en el motor de la base de datos (servidor) mientras que Pandas procesa en la memoria RAM local. ✓



✓ ¿Por qué se recomienda evitar el uso de `SELECT \*` en entornos de producción de ciencia de datos? *5/5

- ☐ Porque SQL bloquea la tabla automáticamente al seleccionar todas las columnas.
- ☐ Porque el comando no es compatible con bases de datos relacionales modernas.
- ☒ Porque transfiere datos innecesarios y aumenta el uso de memoria y ancho de banda. ✓
- ☐ Porque sólo funciona si la tabla tiene menos de 5 columnas.

✓ ¿Qué tipo de JOIN devuelve todos los registros de la tabla izquierda aunque no tengan coincidencias en la tabla derecha? *5/5

- ☐ RIGHT JOIN
- ☐ INNER JOIN
- ☐ CROSS JOIN
- ☒ LEFT JOIN. ✓

✓ ¿Cuál es el equivalente en Pandas para la operación SQL: `SELECT cliente\_id, SUM(monto) FROM ventas GROUP BY cliente\_id`? *5/5

- ☐ df.sum("monto").where("cliente_id")
- ☒ df.groupby("cliente_id")["monto"].sum() ✓
- ☐ df.filter("cliente_id").sum("monto")
- ☐ df.agregate("monto",by="cliente_id")



✓ ¿Cuál es una característica obligatoria de una Clave Primaria (PK)? * 5/5

- ☒ Garantizar la unicidad del registro y la ausencia de valores vacíos (NULL). ✓
- ☐ Ser la columna por la cual se particiona obligatoriamente el archivo Parquet.
- ☐ Ser de tipo string para facilitar la búsqueda en lagos de datos.
- ☐ Permitir valores nulos siempre que la clave sea compuesta.

✓ ¿Por qué SQLAlchemy es la librería estándar recomendada para conectar Python con bases de datos? *5/5

- ☐ Elimina la necesidad de escribir código SQL manualmente.
- ☐ Aumenta la velocidad de procesamiento de Pandas un 500%.
- ☒ Permite trabajar con múltiples motores de bases (MySQL, PostgreSQL, etc.) de datos de forma unificada. ✓
- ☐ Es la única librería que permite exportar datos a archivos CSV.

✓ En el contexto de Feature Engineering, ¿cuál es la función principal de "GROUP BY"? *5/5

- ☐ Ordenar los registros alfabéticamente.
- ☒ Transformar transacciones individuales en métricas agregadas por categoría o usuario. ✓
- ☐ Eliminar duplicados de una tabla sin agruparlos.
- ☐ Conectar dos tablas diferentes.



✓ ¿Qué tipo de JOIN devuelve solo los registros que tienen coincidencias en ambas tablas? *5/5

- ☒ INNER JOIN
- ☐ RIGHT JOIN (asumiendo Clientes a la izquierda)
- ☐ LEFT JOIN (asumiendo Clientes a la izquierda)
- ☐ FULL JOIN



✓ ¿Qué función de la librería Pandas se utiliza para ejecutar una consulta SQL y traer los resultados directamente a un DataFrame? *5/5

- ☐ pd.to_sql()
- ☐ pd.read_csv()
- ☒ pd.read_sql()
- ☐ pd.get_dummies()



✗ Al utilizar create_engine en SQLAlchemy, ¿qué información NO suele incluirse en la cadena de conexión? *0/5

- ☐ El tipo de base de datos (ej. mysql).
- ☒ El nombre de usuario y contraseña.
- ☐ El host y nombre de la base de datos.
- ☐ El nombre de todas las columnas de la tabla.



✓ ¿Qué método de un DataFrame de Pandas se utiliza para persistir o escribir datos de vuelta en una tabla de SQL? *5/5

- ☒ .to_sql()
- ☐ .save_sql()
- ☐ .write_db()
- ☐ .export_sql()



✓ ¿En qué etapa del Pipeline se recomienda realizar cruces (JOINS) y agregaciones complejas? *5/5

- ☐ Durante la Ingesta de archivos CSV.
- ☒ En la Transformación SQL (dentro de la base de datos).
- ☐ Directamente en el modelo de Machine Learning.
- ☐ En el paso de limpieza con Regex.



✓ ¿Por qué es una buena práctica usar Alias de columnas (AS) en SQL al trabajar con DataFrames? *5/5

- ☐ Porque SQL no permite nombres de columnas largos.
- ☐ Para que la base de datos se ejecute más rápido.
- ☐ Para ocultar los nombres originales por seguridad.
- ☒ Para que los nombres de las columnas en el DataFrame resultante sean claros y legibles.



✓ ¿Cuál es el beneficio principal de la Normalización en un modelo relacional? *5/5

- ☒ Reducir la redundancia de datos y mejorar la integridad de la información. ✓
- ☐ Evitar que los usuarios tengan que realizar Joins entre tablas.
- ☐ Hacer que la base de datos sea compatible con formatos NoSQL como MongoDB.
- ☐ Obligar a que todas las columnas sean de tipo texto para mayor flexibilidad.

✓ ¿Qué operador de `WHERE` es fundamental para identificar problemas de calidad de datos como valores faltantes? *5/5

- ☐ IN
- ☐ BETWEEN
- ☒ IS NULL ✓
- ☐ LIKE

✗ ¿Cuál es la forma correcta en SQL de obtener los 10 clientes con mayor gasto total para llevarlos a Python? *0/5

- ☐ Traer toda la tabla y usar df.head(10) en Pandas
- ☒ Usar SELECT * FROM ventas LIMIT 10 ✗
- ☐ Usar GROUP BY cliente_id, ORDER BY total DESC y LIMIT 10 directamente en SQL
- ☐ Aplicar df.sort_values().head(10) después de cargar todo el dataset



✓ ¿Cuál es la diferencia entre WHERE y HAVING en SQL? *

5/5

- ☐ WHERE ordena filas y HAVING las elimina de la tabla
- ☒ WHERE filtra filas antes de agrupar y HAVING filtra grupos después de aplicar GROUP BY ✓
- ☐ HAVING se usa para columnas numéricas y WHERE solo para columnas de texto
- ☐ No existe diferencia; son sinónimos en versiones modernas de SQL

✓ ¿Por qué se recomienda usar params={} con text() de SQLAlchemy en lugar de concatenar strings en una query? *5/5

- ☐ Porque la concatenación de strings no es compatible con MySQL
- ☐ Porque text() convierte automáticamente los resultados a DataFrame
- ☒ Porque la concatenación directa expone el sistema a inyección SQL y no permite reutilizar el plan de ejecución ✓
- ☐ Porque params={} es más rápido únicamente cuando la tabla tiene más de un millón de filas

✓ ¿Cuál de las siguientes es considerada una mala práctica en un entorno profesional con SQLAlchemy? *5/5

- ☐ Usar engine.dispose() al finalizar el script
- ☐ Utilizar variables de entorno con .env para almacenar credenciales
- ☒ Escribir la contraseña de la base de datos directamente en el código fuente y subirlo a GitHub ✓
- ☐ Usar with engine.connect() as conn para manejar la conexión automáticamente

El formulario se creó en Universidad de La Punta. - [Comunicarse con el propietario del formulario](#)



¿El formulario parece sospechoso? [Informe](#)

Google Formularios



