


Diplomatura en python para la ciencia de datos y machine learning

Módulo 2 – Ciencia de Datos y
Machine Learning con Python

MÁSTERCLASS EN APRENDIZAJE SUPERVISADO


LA ODISEA ALGORÍTMICA: REGRESIÓN LOGÍSTICA

De los datos crudos a las decisiones binarias:
Cómo las matemáticas transforman la
incertidumbre en un simple Sí o No.




El Mundo Binario del Aprendizaje Supervisado

Aunque lleva la palabra 'regresión' en su nombre, la Regresión Logística es un algoritmo de clasificación. No predice un valor continuo infinito (como el precio de una casa), sino que estima la probabilidad de que un elemento pertenezca a una categoría específica.




La Falla de la Línea Recta



Regresión Lineal


Genera valores continuos sin límite ($-\infty$ a $+\infty$).
Es matemáticamente absurdo predecir una probabilidad de pertenencia fuera del rango.



Regresión Logística

'Aplasta' cualquier valor real para que encaje perfectamente en un intervalo de probabilidad válido (0, 1).

El Motor de Transformación: La Función Sigmoide




El Logit (z): La combinación lineal de las características del dato, de $-\infty$ a $+\infty$.

La Sigmoide: La base matemática e (≈ 2.718) acota la salida, aplastando el valor.

Probabilidad (p): El resultado final estimado de pertenecer a la clase positiva. Acotado (0, 1).

El Umbral: De la Probabilidad a la Decisión



Regla de Clase:

La sigmoide nos da un número continuo, pero el negocio exige una decisión discreta.

Ajuste de Negocio:

En casos de alto riesgo (como medicina), el umbral se puede bajar a 0.3 para ser más cautelosos y no perder positivos reales (Falsos Negativos).

Caso Práctico: Scoring Crediticio

El Problema: Predecir si un solicitante caerá en impago (Clase 1) o pagará puntualmente (Clase 0).

Profile Card	
Datos del Solicitante	Pesos del Modelo, β
Ingresos (miles €): 3.5	Intercepto (β_0): -1.20
Deuda total (miles €): 4.2	Ingresos (β_1): -0.42 (Reduce el riesgo)
Nº Tarjetas: 2	Deuda (β_2): +0.85 (Aumenta el riesgo)
	Tarjetas (β_3): +0.10 (Aumenta el riesgo)

Calculando el Veredicto (Pasos 1 y 2)

Paso 1: La Combinación Lineal, z

$$z = \beta_0 + (\beta_1 \cdot \text{Ingresos}) + (\beta_2 \cdot \text{Deuda}) + (\beta_3 \cdot \text{Tarjetas})$$

$$z = -1.20 + (-0.42 \cdot 3.5) + (0.85 \cdot 4.2) + (0.10 \cdot 2)$$

$$z = -1.20 - 1.47 + 3.57 + 0.20 = 1.10$$

$$z = 1.10$$

Paso 2: La Transformación Sigmoides, P

$$P = \frac{1}{1 + e^{-1.10}}$$

$$P = \frac{1}{1 + 0.3329}$$

$$P \approx 0.750$$

El Veredicto Final: Cruzando el Umbral



RECHAZADO

El Resultado

El modelo estima una probabilidad de impago del 75% ($p = 0.75$).

La Decisión

Dado que $0.75 > 0.5$ (nuestro umbral estándar), el algoritmo clasifica a este solicitante como **"Riesgo Alto" (Clase 1)**.

Acción de Negocio

Crédito Rechazado.

Diagnóstico Comparativo: Lineal vs Logística

	Regresión Lineal	Regresión Logística
Salida	Valores continuos sin límite	Probabilidades acotadas (0 a 1)
Uso Principal	Predicción numérica (precios, clima)	Clasificación binaria (fraude, spam)
Linealidad	Relación directa variables-respuesta	Linealidad en los log-odds (frontera lineal)
Sensibilidad a Outliers	Muy sensible (mínimos cuadrados)	Robusta (la sigmoide acota el impacto)
Interpretabilidad	Cambio directo por unidad	Intuitiva mediante Odds Ratios ($\exp(\beta)$)

SECCIÓN

Matriz de Confusión y Métricas

El Escenario: Evaluando un Modelo Médico



El Problema:

Tenemos un modelo de clasificación binaria diseñado para detectar una enfermedad.

Las Clases:


Positivo = Enfermo | Negativo = Sano.

La Prueba:

Hemos evaluado el modelo con los datos de 100 pacientes reales para comprobar su eficacia.

Midiendo el Éxito: La Matriz de Confusión

La Exactitud (Accuracy) es una trampa en bases de datos desbalanceadas. Si una enfermedad rara solo afecta al 1%, un modelo que siempre diga "Sano" tendrá un 99% de exactitud, pero será inútil.



La Matriz en la Práctica: Nuestro Modelo Médico

TP
50

FP
5

FN
10

TN
35

- 50 pacientes enfermos fueron detectados correctamente.
- 5 pacientes sanos fueron diagnosticados erróneamente como enfermos.
- 10 pacientes enfermos no fueron detectados.
- 35 pacientes sanos fueron clasificados correctamente.

```
from sklearn.metrics import confusion_matrix  
cm = confusion_matrix(y_test, y_pred)  
print(cm)
```

1. Exactitud (Accuracy)

¿Qué porcentaje de predicciones fueron correctas en general?

TP	FP
FN	TN
TP	FP
FN	TN

$$\text{Accuracy} = \frac{50 + 35}{50 + 35 + 5 + 10} = \frac{85}{100} = 0.85 \text{ (85\%)}$$

De 100 predicciones, 85 fueron correctas.

```
from sklearn.metrics import accuracy_score
accuracy = accuracy_score(y_test, y_pred)
print(f'Accuracy: {accuracy:.2f}')
```

2. Precisión (Precision)

De todos los casos que el modelo predijo como positivos, ¿cuántos realmente lo eran?

TP 50	FP 5
FN 10	TN 35
TP 50	FP 5
FN 10	TN 35

$$\text{Precision} = \frac{50}{50 + 5} = \frac{50}{55} \approx 0.91 \text{ (91\%)}$$

Cuando el modelo dice que alguien está enfermo, es altamente confiable (91% de las veces acierta).

```
from sklearn.metrics import precision_score
precision = precision_score(y_test, y_pred)
print(f'Precision: {precision:.2f}')
```

3. Sensibilidad (Recall)

De todos los positivos reales, ¿cuántos logró detectar el modelo?

$$\text{Recall} = \frac{50}{50 + 10} = \frac{50}{60} \approx 0.83 \text{ (83\%)}$$

El modelo detecta a la mayoría, pero se le escapan 10 pacientes enfermos reales (Falsos Negativos).

TP 50	FP
FN	TN

TP 50	FP
FN 10	TN

```
from sklearn.metrics import recall_score  
  
recall = recall_score(y_test, y_pred)  
print(f'Recall: {recall:.2f}')
```

4. F1-Score: La Medida Combinada

La media armónica. El equilibrio perfecto cuando no puedes elegir entre Precisión y Recall.



$$F1 = 2 * \left(\frac{(0.91 * 0.83)}{(0.91 + 0.83)} \right) \approx 0.87 (87\%)$$

```
from sklearn.metrics import f1_score

f1 = f1_score(y_test, y_pred)
print(f'F1-score: {f1:.2f}')
```

El Veredicto Final del Modelo

Accuracy

85%

El modelo **acierta el 85% de las veces** en general. Un desempeño global sólido.

Precision

91%

Las alarmas son **precisas**. Cuando diagnostica a alguien como enfermo, casi siempre tiene razón.

Recall

83%

El punto débil. Detecta **a la mayoría**, pero un 17% de los pacientes enfermos escapan al diagnóstico.

F1-Score

87%

Un balance general **alto**, demostrando que el modelo es robusto a pesar de los falsos negativos.

Cheat-Sheet: ¿Qué Métrica Elegir?

Métrica	¿Qué responde?	¿Cuándo usarla fundamentalmente?
Accuracy	¿Qué porcentaje de predicciones fueron correctas?	Cuando las clases están equilibradas (mismos sanos que enfermos).
Precisión	De los positivos predichos, ¿cuántos eran realmente positivos?	Cuando interesa minimizar los falsos positivos (ej. evitar tratamientos agresivos a personas sanas).
Recall / Sensibilidad	De los positivos reales, ¿cuántos detectó el modelo?	Cuando interesa minimizar los falsos negativos (ej. es letal no detectar una enfermedad).
F1-score	¿Cuál es el equilibrio entre Precisión y Recall?	Cuando ambas métricas son críticas o las clases están muy desbalanceadas.