


Diplomatura en python para la ciencia de datos y machine learning

MÓDULO 2 - Aprendizaje Supervisado

K-Vecinos Más Cercanos
(KNN)



Regresión Lineal

Ejemplo: Horas de estudio vs. Calificación obtenida

Objetivo:

Predecir la calificación de un estudiante (de 0 a 100) en función de las horas que estudia.

Datos observados


Horas de estudio (x)	Calificación (y)
1	50
2	55
3	60
4	63
5	70
6	72
7	75
8	80
9	85
10	90

Ecuación de la recta:

Calificación (y) = 42 + 4.8 × Horas (x)
 $y = 4.8x + 42$

Interpretación:

- Por cada hora adicional de estudio, la calificación aumenta en promedio 4.8 puntos.
- La calificación esperada cuando no se estudia (0 horas) es 42 puntos.



Ejemplos de predicciones con la recta de regresión

Horas de estudio (x)	0	2	4	6	8	10	12
Calificación estimada (y)	42.0	51.6	61.2	70.8	80.4	90.0	99.6

Nota: Este ejemplo es didáctico. En la realidad, la calificación también depende de otros factores como la calidad del estudio, la dificultad del tema, el descanso, la motivación, entre otros.

Regresión Logística

Ejemplo: Clasificación de Correo Spam vs. No Spam

Objetivo

Predecir si un correo es Spam (1) o No Spam (0) según la cantidad de palabras clave sospechosas que contiene (ej. "gratis", "oferta", "gane dinero").

Modelo (Sigmoide)


Probabilidad de Spam (y) = $1 / (1 + e^{(-z)})$

$z = -4.5 + 1.0 \cdot \text{Palabras sospechosas (x)}$

Umbral de decisión: $p = 0.5$

Interpretación

A más palabras clave sospechosas, mayor la probabilidad de spam. Con 4-5 palabras el modelo está "indeciso" ($p \approx 0.5$); por encima del umbral, se clasifica como Spam.



¿Qué es KNN? (K-Vecinos Más Cercanos)

Concepto Fundamental

Es un algoritmo de aprendizaje automático SUPERVISADO que se utiliza tanto para clasificación como para regresión.


Lógica Intuitiva

“Dime con quién andas y te diré quién eres”. Clasifica o predice el valor de un nuevo dato basándose en la mayoría de sus vecinos más cercanos.

Funcionamiento Clave


No requiere entrenamiento previo (“Lazy Learner”). · Memoriza los datos de entrenamiento. · Calcula distancias (ej. Euclídea) para encontrar los vecinos más cercanos. · La “K” define cuántos vecinos se consideran.

- Clase A: Aprobado
- Clase B: Desaprobado



Votación (K=3): 2 Desaprobado, 1 Aprobado → Clasificación Final: Desaprobado. Con K=1 el resultado también sería Desaprobado.

El algoritmo, paso a paso



Eligiendo el valor de k


k pequeño (ej. k = 1)

Frontera muy irregular, sensible al ruido: alta varianza (overfitting).

k grande (ej. k = 30)


Frontera muy suavizada, pierde detalle: alto sesgo (underfitting).

El valor óptimo se busca con validación cruzada, probando distintos k.



Fronteras de Decisión

k = 1 → Sobreajuste



k = 1 → Sobreajuste

La frontera sigue cada punto individual, incluso el ruido. Alta varianza, mala generalización.

k grande → Subajuste



k grande → Subajuste

La frontera se vuelve casi una línea recta, ignorando la estructura real de los datos. Alto sesgo.

KNN para Regresión

Ejemplo: Predicción de Precio de Casa

1

Encontrar Vecinos:

Localizar las k casas más similares en el espacio de variables (superficie, habitaciones, etc.).

2

Recopilar Precios:

Obtener los precios reales de los k vecinos identificados.

3


Cálculo de Valor:

Calcular el promedio (o promedio ponderado) de los precios obtenidos.

4

Predicción →

Valor numérico promedio de los precios.



$k = 3 \rightarrow \text{Predicción Promedio} = \$305k$
 $((\$310k + \$305k + \$300k) / 3)$

KNN para Clasificación

Aplicación: Clasificación de Vivienda (Cara o Económica) según Características

1

Variables de Entrada

Capturar características clave de la propiedad: Superficie (m^2), Habitaciones, Ubicación y Antigüedad.

2

Definir Clases Históricas

Etiquetar viviendas registradas según su precio de mercado: 'Cara' (Rojo) o 'Económica' (Verde).

3

Localizar Vecinos (Distancia)

Medir similitud geométrica de la nueva vivienda con los registros históricos para hallar las k más cercanas.

4

Predicción del Segmento (Votación)

Asignar la categoría mayoritaria entre los k vecinos más cercanos analizados (ej. $k=5$).



✓ Votación Mayoritaria ($k=5$)

3 Vecinos Económicos vs. 2 Vecinos Caros → Predicción Final: Vivienda Económica

Escalado de Variables

Si las variables tienen escalas distintas (ej. edad 0–100 vs. ingreso 0–100.000), la de mayor magnitud domina la distancia y distorsiona al modelo.

Normalización (Min-Max)

$$x' = (x - \min) / (\max - \min)$$

Estandarización (Z-score)

$$x' = (x - \mu) / \sigma$$

Sin escalar (distorsionado)



Escalado (balanceado)



Selección de k mediante Validación Cruzada

El Proceso

1. Elegir varios valores de K candidatos (1, 3, 5, 7, 9...).
2. Aplicar Validación Cruzada (5-Fold) para cada valor.
3. Calcular el Accuracy promedio de las iteraciones.
4. Seleccionar el K con mayor Accuracy promedio.
5. Entrenar el modelo final con ese K óptimo.

Simulación de Selección

K = 1	89.6%
K = 3	92.4%
K = 5 (Óptimo)	95.0% ✓
K = 7	94.0%

K = 5 representa el punto de equilibrio óptimo con un 95.0% de precisión estimada.

¿Por qué es clave?

Evita el sobreajuste: reduce el riesgo de un K viciado por ruido local.

Eficiencia de datos: aprovecha al máximo los datos al rotar los folds.

Decisión científica: fundamenta la elección del hiperparámetro.

Métrica estable: estima mejor el rendimiento futuro real.

“La validación cruzada permite comparar distintos valores de K y seleccionar el que ofrece el mejor desempeño promedio antes de entrenar el modelo final.”

Matriz de Confusión y Métricas Clave

		Clases Reales	
		Positivo (+)	Negativo (-)
Predicho (+ / -)	Positivo (+)	VP Verdadero Positivo	FP Falso Positivo
	Negativo (-)	FN Falso Negativo	VN Verdadero Negativo

✓ Aciertos: VP y VN son las clasificaciones correctas.

✗ Errores: FP (Error Tipo I) y FN (Error Tipo II) guían el ajuste del algoritmo.

ACCURACY (Exactitud)

$$(VP + VN) / TOTAL$$

¿Qué proporción de todas las predicciones fue correcta?

PRECISIÓN

$$VP / (VP + FP)$$

De las predicciones positivas, ¿cuántas fueron correctas?

RECALL (Sensibilidad)

$$VP / (VP + FN)$$


De los casos positivos reales, ¿cuántos identificó el modelo?

F1-SCORE

$$2 \cdot (P \cdot R) / (P + R)$$

Balance armónico entre Precisión y Recall.

La Curva ROC y el Área Bajo la Curva (AUC)



¿Qué es la Curva ROC?

Es una representación gráfica que contrasta la **Tasa de Verdaderos Positivos** (TPR / Sensibilidad) frente a la **Tasa de Falsos Positivos** (FPR) para cada umbral de decisión.

Eje Y: Sensibilidad (TPR)

Proporción de casos positivos reales identificados correctamente por el modelo.

Eje X: FPR (1 - ESP)

Proporción de casos negativos reales que el modelo clasifica incorrectamente como positivos.


Interpretación del AUC

- **AUC = 1.0:** Clasificador perfecto, separación absoluta.
- **AUC = 0.5:** Rendimiento equivalente al azar.
- **AUC = 0.83:** Excelente capacidad discriminativa.

0.83

“El AUC proporciona una métrica global del rendimiento del modelo que es robusta ante el desbalance de clases, evaluando la calidad de las predicciones probabilísticas.”

Métricas Avanzadas




ROC-AUC = 0.83

Mide la capacidad de separar clases en todos los umbrales posibles. 1.0 = perfecto, 0.5 = azar.

Validación Cruzada para elegir k

GridSearchCV prueba varios valores de k (1, 3, 5, 7...) y promedia el accuracy en cada fold.

El k con mejor promedio en validación es el que se usa en el modelo final.



Métricas de Evaluación de Regresión

¿Cómo medimos qué tan cerca están nuestras predicciones de los valores reales?

MAE

Error Absoluto Medio

Representa el promedio de las diferencias absolutas entre las predicciones y los valores reales sin importar su dirección.

$$\text{MAE} = (1/n) * \sum |y - \hat{y}|$$

- Fácil de interpretar: usa las mismas unidades que la variable dependiente.
- No penaliza los errores grandes de manera desproporcionada.

MSE / RMSE

Error Cuadrático Medio

Mide el promedio de los errores al cuadrado. Su raíz (RMSE) vuelve a la escala original de los datos.

$$\text{RMSE} = \sqrt{[(1/n) * \sum (y - \hat{y})^2]}$$

- Penaliza severamente los errores grandes o "outliers".
- Es la métrica de pérdida matemática estándar para optimizar modelos de regresión.

R² / R² Ajustado

Coefficiente de Determinación

Indica la proporción de la varianza en la variable dependiente que es predecible a partir de las variables independientes.

$$R^2 = 1 - (\text{SS}_{\text{res}} / \text{SS}_{\text{tot}})$$

- Varía típicamente entre 0 y 1 (donde 1 es un ajuste perfecto).
- La versión ajustada penaliza la adición de variables irrelevantes.

Métricas de Evaluación según el Modelo

REGRESIÓN

Regresión Lineal

MÉTRICAS RECOMENDADAS

MAE, RMSE, R^2

¿QUÉ MIDE?

Error promedio, magnitud del error y capacidad explicativa del modelo.

CLASIFICACIÓN

Regresión Logística

MÉTRICAS RECOMENDADAS

Accuracy, Precision, Recall, F1-score, ROC-AUC

¿QUÉ MIDE?

Calidad de la clasificación y capacidad para distinguir las clases.

REGRESIÓN

KNN Regresión

MÉTRICAS RECOMENDADAS

MAE, RMSE, R^2

¿QUÉ MIDE?

Diferencia entre los valores reales y los predichos.

CLASIFICACIÓN

KNN Clasificación

MÉTRICAS RECOMENDADAS

Accuracy, Precision, Recall, F1-score, ROC-AUC

¿QUÉ MIDE?

Desempeño del modelo al asignar categorías.

Ventajas, Desventajas y Variantes

Ventajas

- ✓ Simple e intuitivo de entender e implementar.
- ✓ No paramétrico: no asume una distribución de los datos.
- ✓ Fácil de actualizar: solo hay que agregar nuevos datos.

Desventajas

- ✗ Costoso en datasets grandes: compara con todos los puntos.
- ✗ Sensible a la escala y a variables irrelevantes.
- ✗ Sufre la “maldición de la dimensionalidad” con muchas variables.

KNN ponderado (weighted)

Los vecinos más cercanos pesan más en la votación, típicamente con $\text{peso} = 1 / \text{distancia}$.