

DEL MODELO A LA CONCLUSIÓN

Cómo interpretar y comunicar resultados de Machine Learning

Módulo II · Ciencia de Datos e Introducción a Machine Learning

DEL MODELO A LA CONCLUSIÓN

Cómo interpretar y comunicar resultados de Machine Learning

Entrenar es solo una parte del trabajo.

Un modelo cobra valor cuando podemos explicar qué hizo, qué tan bien funciona, dónde puede fallar y qué decisiones permite tomar.

01 Datos

02 Modelo

03 Métricas

04 Interpretación

05 Decisión

¿CUÁNDO TERMINA UN PROYECTO DE ML?

Entrenamos el modelo y obtuvimos una métrica. ¿Terminamos?

Métrica Obtenida

Accuracy = 0,78

¿Terminamos el proyecto?

¡NO!

01 ¿Qué significa 0,78?

02 ¿Qué errores está cometiendo?


03 ¿Es suficiente para este problema?

04 ¿Qué limitaciones tiene?

05 ¿Qué podemos concluir?

“Una métrica es el comienzo de la interpretación, no el final.”

UNA MÉTRICA NO ES UNA CONCLUSIÓN



MÉTRICA ≠ INTERPRETACIÓN ≠ CONCLUSIÓN

TRADUCIR LAS MÉTRICAS AL PROBLEMA

El número técnico debe volver a las unidades y al contexto original.

REGRESIÓN

MAE = \$85.000

NO SOLO

“El MAE es 85.000.”

MEJOR

“Las predicciones se alejan del valor real aproximadamente \$85.000 en promedio.”

CLASIFICACIÓN

Recall = 0,72

NO SOLO

“El Recall es 0,72.”

MEJOR

“El modelo detecta aproximadamente el 72 % de los casos positivos reales.”

NO MOSTRAR SOLO LOS ACIERTOS

Los errores también cuentan la historia.

MATRIZ DE CONFUSIÓN

	Predice NO	Predice SÍ
Real NO	120	18
Real SÍ	25	37

ERROR CRÍTICO

25 clientes abandonaron y el modelo no los detectó.


¿Es ese error aceptable?

Depende del problema y del costo de equivocarse.

El error más importante depende del problema que queremos resolver.

EN REGRESIÓN, ¿DÓNDE SE EQUIVOCA?

Un buen promedio puede esconder errores importantes en casos individuales.



CERCA DE LA DIAGONAL

Predicción cercana al valor real.

Menor error.



LEJOS DE LA DIAGONAL

Mayor error de predicción.

Puede sobreestimar o subestimar.

Mayor impacto en el resultado.



PREGUNTA CLAVE

¿Los errores son similares
para todos los casos?

Analicemos caso por caso.

COMPARAR MODELOS

Mismo problema, distintos comportamientos.

Modelo	Accuracy	Precision	Recall	F1
Logística	0,79	0,72	0,63	0,67
KNN	0,77	0,68	0,60	0,64
Árbol	0,74	0,61	0,66	0,63
Random Forest	0,78	0,70	0,62	0,66

¿CUÁL ES EL MEJOR MODELO?

La tabla no responde sola: primero debemos definir qué error importa más.

“MEJOR” DEPENDE DEL OBJETIVO

ACCURACY

Acertar globalmente · ¿Cuántos casos clasificamos bien?

PRECISION

Evitar falsas alarmas · De los positivos predichos, ¿cuántos eran realmente positivos?

RECALL

Detectar positivos · De los positivos reales, ¿cuántos encontramos?

F1

Buscar equilibrio · Combina Precision y Recall.

Las métricas ayudan a decidir. No deciden por nosotros.

COMPARAR SIN EXAGERAR

La forma de escribir cambia la calidad de la conclusión.

EVITAR

✗

“Random Forest destruyó a los demás modelos.”

✗

“82 % de Accuracy: funciona perfectamente.”

✗

“KNN demostró ser el mejor algoritmo.”

PREFERIR

✓

“Random Forest obtuvo el mayor F1 entre los modelos evaluados.”

✓

“El modelo alcanzó 82 % de Accuracy, pero aún comete errores.”

✓

“En este conjunto de datos, KNN obtuvo el mejor resultado según la métrica seleccionada.”

Comparar con precisión: qué modelo, qué métrica, qué datos y qué diferencia.

UN MODELO TAMBIÉN TIENE LIMITACIONES

Datos disponibles

Tamaño de muestra

Valores faltantes

Desbalance

Outliers

Overfitting

Variables utilizadas

Cambios futuros

Una predicción es una estimación basada en datos, no una certeza.

PATRÓN NO SIGNIFICA CAUSALIDAD

El modelo puede encontrar asociaciones sin explicar por qué ocurren.

OBSERVAMOS

Los clientes con más reclamos presentan mayor abandono.



¿PODEMOS AFIRMAR?

“Los reclamos causan el abandono.”

NO NECESARIAMENTE


Puede haber otras variables, relaciones indirectas o información que no estamos observando.

Predecir bien no equivale a demostrar una relación causal.

¿Y K-MEANS?

Los clusters necesitan interpretación humana.

K-Means encontró 4 clusters



INTERPRETAR EL CLUSTER 2

↑ reclamos
↓ satisfacción
↓ antigüedad

Interpretación posible:
“Clientes relativamente nuevos, con baja satisfacción y mayor cantidad de reclamos.”

El nombre del perfil es nuestra interpretación; no una verdad descubierta automáticamente por K-Means.

DE RESULTADO A CONCLUSIÓN

Construir una conclusión es un proceso.

DATO

F1 = 0,68



INTERPRETACIÓN

Equilibrio moderado entre Precision y Recall.



CONTEXTO

Queremos detectar clientes con riesgo de abandono.



LIMITACIÓN

Algunos clientes que abandonan todavía no son detectados.



CONCLUSIÓN

Puede apoyar la identificación de clientes a revisar, pero no debería decidir automáticamente.

¿QUÉ DEBE TENER UN INFORME BÁSICO DE ML?

Seis preguntas alcanzan para organizar una comunicación clara.

01

¿Qué problema intentamos resolver?

02

¿Con qué datos trabajamos?

03

¿Qué modelos evaluamos?

04

¿Qué resultados obtuvimos?

05

¿Qué errores y limitaciones encontramos?

06

¿Qué podemos concluir o recomendar?

El informe debe permitir comprender el problema, el resultado y sus límites sin leer el código.

EJEMPLO DE CONCLUSIÓN EJECUTIVA

Caso: abandono de clientes

Objetivo: identificar clientes con riesgo de abandonar el servicio.

Se evaluaron cuatro modelos de clasificación utilizando información histórica de clientes. La Regresión Logística obtuvo el mejor equilibrio entre las métricas consideradas, aunque las diferencias con otros modelos fueron moderadas.

El modelo permite identificar una parte importante de los clientes con riesgo, pero también produce errores. Sus predicciones deberían utilizarse como apoyo y no como decisión automática.

Los resultados corresponden a los datos analizados y podrían cambiar frente a nuevos clientes o cambios en su comportamiento.

¿DÓNDE
ESTÁ EL
CÓDIGO?

No está.

El destinatario necesita comprender el resultado, no necesariamente la implementación.

ACTIVIDAD FINAL

Detectar problemas en una conclusión exagerada.

“Random Forest obtuvo un Accuracy del 81 %, demostrando que es un modelo altamente confiable y que permitirá predecir correctamente qué clientes abandonarán la empresa.”

¿QUÉ PROBLEMAS ENCUENTRAN?

¿Exagera?

¿Confunde Accuracy con certeza?

¿Ignora errores?

¿Faltan otras métricas?

¿Menciona limitaciones?

Objetivo: transformar una afirmación fuerte en una conclusión precisa y responsable.

CIERRE DEL MÓDULO II

DATOS

EXPLORAR

PREPARAR

MODELAR

EVALUAR

INTERPRETAR

>

COMUNICAR

NO SOLO SE TRATA DE...

Obtener predicciones

Machine Learning no consiste solamente en la generación automatizada de métricas y resultados brutos.

SINO TAMBIÉN DE...

Comprender y comunicar

Consiste en saber qué significan, qué tan confiables son y cómo transmitirlos de forma responsable.

Trabajo Práctico Integrador

Caso de Estudio: Empresa de Telecomunicaciones

Aplicá los contenidos del módulo para analizar el caso y construir una solución de Machine Learning.



Dataset del TP

Descargá el conjunto de datos que utilizarás durante todo el trabajo práctico.

ABRIR DATASET →



Cuaderno Colab

Abrí la plantilla en Google Colab. Allí encontrarás las consignas, la estructura del análisis y los bloques de código que deberás completar.

[ABRIR CUADERNO COLAB →](#)