

Conclusiones del TP de seguros Médicos



[Descargar la notebook](#)


Hallazgo #1: Sesgo positivo en los gastos

Conclusión: Fuerte sesgo positivo en charges

Al comparar las medidas de tendencia central, observamos:

- **Moda:** Representada por la barra más alta, indica el valor más frecuente.
- **Mediana:** Divide la distribución a la mitad.
- **Media:** Desplazada hacia la derecha por valores extremos.

Relación: Moda < Mediana < Media



```
moda= df[variables].mode().iloc[0]
resumen= pd.DataFrame({'media': media, 'mediana': mediana, 'moda': moda}).round(2)
resumen
```

	media	mediana	moda
charges	13270.42	9382.03	1639.56
hmi	30.66	30.40	32.30


Hallazgo #2: Impacto del Tabaquismo

Conclusión: Los Fumadores gastan significativamente más.

El análisis comparativo revela una disparidad drástica en los costos médicos entre ambos grupos:

- **Gasto Promedio (Fumadores): \$32,050 USD**
- **Gasto Promedio (No Fumadores): \$8,434 USD**
- *Los fumadores incurren en gastos casi 4 veces superiores a los no fumadores.*

Gastos médicos promedio por estado de fumador



```
# Tu código aquí  
df.groupby('smoker')['charges'].agg(['mean', 'median']).round(2)
```

	mean	median
smoker		
no	8434.27	7345.41
yes	32050.23	34456.35

Análisis Estadístico y Comparativa de Gastos Médicos (USD)

Los Outliers no siempre son errores

Conclusión: Perfil de Cliente Crítico

Identificación de Anomalías:


- Se detectaron **139 valores atípicos (outliers)** en la distribución de gastos médicos.
- Representan el **10.4% del total** de la muestra, superando el límite de **\$16,640**.
- La distribución es fuertemente asimétrica a derecha (skew = 1.52).

¿Por qué no son errores?

No son datos incorrectos, sino un perfil de cliente real y crítico para el análisis.

El Factor Determinante:

- El **97.8% de estos gastos extremos** corresponden a pacientes **fumadores**.
- El tabaquismo define los costos más altos.



La alta concentración de puntos (outliers) por encima de los \$16,640 no es ruido estadístico; refleja el impacto directo del hábito de fumar en los costos de salud.


El boxplot empieza a perder capacidad descriptiva cuando hay muchos atípicos

Distribución de los gastos médicos (Charges)

Análisis de densidad. Distribución de Charges (Violin Plot)

El violín muestra la densidad en cada valor: el ensanchamiento en la parte inferior indica que **la mayoría de clientes tiene gastos bajos**. La cola derecha larga revela la concentración de fumadores con gastos extremos. El boxplot solo muestra Q1/Q3 y outliers como puntos.


- Los outliers reflejan un subgrupo real, no error de medición.
- El violin revela la distribución bimodal: un grupo de bajo gasto (no fumadores) y un grupo de alto gasto (fumadores). El boxplot no muestra esta estructura.



Distribución de Charges y densidad de observaciones. Los valores extremos están ligados al tabaquismo.

Ejercicio 4.3 — BMI por categoría y outliers

El boxplot por categoría confirma la consistencia de la clasificación



- No se trata de errores, sino de individuos en los límites de su categoría.
- El factor modulador sigue siendo el tabaquismo. El BMI amplifica el riesgo solo dentro del grupo fumador.

Estos outliers de BMI elevan los charges?

No directamente.
Solo en fumadores el BMI alto dispara los gastos ($r = 0.806$ vs 0.084).


La categorización de BMI es consistente. Los outliers de BMI son límites de categoría, no errores. El BMI extremo eleva los gastos solo en fumadores (Hallazgo #3).

Análisis de Outliers y bmi

Conclusión: BMI Extremo vs. Gastos

Usando el método Z-score ($|z| > 3$), se identificaron 4 outliers en `bmi`.

- Valores superiores a 49.
- No todos son fumadores.
- Los `charges` varían considerablemente a pesar del BMI elevado.



```
df['z_bmi'] = stats.zscore(df['bmi'])


outliers_z = df[df['z_bmi'].abs() > 3]
print(f'Outliers Z-score  $|z| > 3$  en bmi: {len(outliers_z)}')
print(outliers_z[['age', 'sex', 'bmi', 'z_bmi', 'smoker', 'charges']])
```

Sin relación entre BMI y Tabaquismo

Conclusión: Ausencia de correlación lineal

El análisis de la relación entre el hábito de fumar y el índice de masa corporal (BMI) revela:

- **Pearson ($r = 0.004$):** Correlación extremadamente baja y estadísticamente no significativa ($p = 0.891$).
- **Similitud Visual:** Los boxplots muestran distribuciones casi idénticas entre fumadores y no fumadores.
- **Independencia:** Ser fumador no parece influir en el BMI del individuo en este conjunto de datos.



```
r= stats.pearsonr(df['smoker_num'], df['bmi'])  
(smoker_num, bmi) = {r_pearson: .3f} (p=  
num, bmi) = 0.004 (p= 0.891)
```

Ejercicio 5.1 y 5.5 — Multicolinealidad

Correlacion de Pearson entre todas las variables numericas

Factores clave para charges


- smoker_num: $r = 0.79$ predictor principal
- age: $r = 0.30$ correlación moderada
- bmi: $r = 0.20$ correlación débil
- children: $r = 0.07$ impacto mínimo

Multicolinealidad detectada

- bmi vs peso_kg: $r = 1.00$ (perfecta)
- peso_kg fue derivada de bmi + ruido
- **Accion: conservar bmi, descartar peso_kg**
- bmi es la variable original con interpretación clínica directa

- No hay otros pares de features con $|r| > 0.5$ (excluyendo charges y smoker_num).
- Features para el modelo: smoker_num, age, bmi, children.

Se conserva bmi y se descarta peso_kg: ambas son idénticas ($r = 1.00$), pero bmi es la variable original con significado clínico. Incluir ambas causaría inestabilidad en el modelo.



Ejercicio 5.2 — Los fumadores tienen mayor BMI?

Correlación de Pearson entre smoker_num y bmi

$r = 0.004$

Pearson (smoker vs bmi)

$p = 0.891$

No significativo

$\approx$ Igual

BMI por grupo

- La correlación de 0.004 es prácticamente cero: fumar no predice el BMI.
- El p-valor de 0.891 confirma que la correlación no es estadísticamente significativa.
- Los boxplots de BMI para fumadores y no fumadores muestran medianas e IQR casi idénticos.
- Importante: esto descarta una posible confusión. Si fumadores tuvieran mayor BMI, no podríamos aislar el efecto de cada variable en los charges.


Fumar y el BMI son variables independientes en este dataset. Podemos analizar su efecto por separado sin riesgo de confusión entre ambas.

Hallazgo #3: BMI resulta relevante dentro del grupo de Fumadores

Conclusión: Impacto del BMI en Fumadores

El hábito de fumar actúa como un multiplicador del gasto médico vinculado al BMI:

- **No Fumadores (Azul):** Gastos estables y bajos, independientemente del BMI (relación casi nula).
- **Fumadores (Naranja):** Correlación positiva fuerte; el gasto se dispara a medida que aumenta el BMI.
- **Diferenciación:** La relación BMI-Gasto es drásticamente distinta según el estado de fumador.



```
r_fum= fumadores['bmi'].corr(fumadores['charges'])
r_no_fum= no_fumadores['bmi'].corr(no_fumadores['charges'])
print(f'Correlación Pearson (BMI vs Charges) para fumadores: r = {r_fum:.3f}')
print(f'Correlación Pearson (BMI vs Charges) para no fumadores: r = {r_no_fum:.3f}')
```


Correlación Pearson (BMI vs Charges) para fumadores: r = 0.806
Correlación Pearson (BMI vs Charges) para no fumadores: r = 0.084

BMI como Predictor de Gasto Médico

Conclusión Principal

El impacto del BMI en el gasto médico depende críticamente del tabaquismo:

- Fumadores (Naranja): Correlación **positiva y muy fuerte** ($r = 0.806$). A mayor BMI, el gasto aumenta drásticamente.
- No Fumadores (Azul): Correlación muy débil ($r = 0.084$). El BMI tiene un impacto mínimo en los gastos.



Perfil del Cliente de Alto Costo

Tabaquismo

El **97.8%** de los clientes de alto costo son fumadores.

IMC Elevado

Promedio de **35.6** vs 29.8 en clientes de bajo costo.

Edad Avanzada

Los clientes de alto costo tienen en promedio **14 años más** que los de bajo costo.

	n	edad_media	pct_fumadores	bmi_medio	charges_media	region_top
grupo						
Bajo costo (<P25)	335	23.8	0.0	29.9	2853.0	southeast
Alto costo (>P75)	335	40.2	76.1	31.3	31108.0	southeast

```
p25 = df['charges'].quantile(0.25)
p75 = df['charges'].quantile(0.75)

alto_costo = df[df['charges'] > p75].copy()
bajo_costo = df[df['charges'] < p25].copy()
```

Ser fumador es el predictor principal de alto costo (97.8%). El BMI elevado y la edad avanzada amplifican el riesgo. La región geográfica (sureste) no discrimina entre grupos.

Ejercicio 6.2 — BMI como Predictor Condicional

La relacion BMI-charges depende criticamente del tabaquismo

Interpretacion

Fumadores ($r = 0.806$)

Correlacion muy fuerte. A mayor BMI los gastos se disparan. El tabaquismo cataliza el riesgo metabolico.


No Fumadores ($r = 0.084$)

Sin relacion practica. El BMI tiene impacto minimo en los gastos para este grupo.

Para el modelo predictivo:

Incluir `bmi x smoker_num` como interaccion. Sin el, el efecto del BMI queda subestimado en fumadores y sobrestimado en no fumadores.

Correlacion Pearson BMI vs Charges



El BMI es predictor fuerte ($r=0.806$) en fumadores, y casi irrelevante en no fumadores ($r=0.084$). El modelo estimado por el `lm` no incluye la interaccion explicitamente con el termino `bmi x smoker_num`.

Factores Determinantes de Gastos Médicos

[1] Factor Principal: Tabaquismo

Es el impulsor más crítico de los costos médicos:

- **Correlación Fuerte:** $r = 0.79$ entre fumadores y cargos.
- **Gasto Elevado:** Los fumadores gastan casi 4 veces más (\$32,050 vs \$8,434).
- **Concentración:** El 97.8% de los gastos en el percentil superior pertenecen a fumadores.

Conclusión: El tabaquismo domina el análisis de varianza de costos.

Otros Factores Relevantes

[2] Edad (age)

Correlación positiva moderada ($r = 0.30$). A mayor edad, los gastos tienden a subir gradualmente.

[3] BMI x Tabaquismo

Relación dependiente: Muy fuerte en fumadores ($r = 0.806$), pero casi nula en no fumadores ($r = 0.084$).

[4] Hijos

Impacto mínimo y correlación muy débil ($r = 0.07$) en el modelo estadístico general. No es un predictor relevante en el modelo estadístico general.