

UNIDAD 1 · CLASE 1

Estadística descriptiva I

*Tipos de variables, medidas de centro
y tu primera intuición sobre los datos*

Modulo II · Ciencia de Datos e Introducción a Machine Learning

Estadística Aplicada en Ciencia de Datos

Cómo transformar datos en información para tomar decisiones

- ▶ ¿Cómo resumimos grandes volúmenes de datos?
- ▶ ¿Cómo detectamos patrones?
- ▶ ¿Cómo tomamos decisiones con incertidumbre?

**“Sin estadística,
los datos son
solo números.”**

¿Qué es dato?

Un dato es una representación simbólica (numérica, alfabética, etc.) de un atributo o variable. Los datos describen hechos empíricos, sucesos y entidades.




- Es el bloque de construcción de la información.
- Puede ser **estructurado** o **no estructurado**.
- Por sí solo **no tiene significado**.

“Los datos no son información, la información no es conocimiento, el conocimiento no es sabiduría.” - Clifford Stoll



¿Qué es una variable?

Todo lo que podemos medir o clasificar en un dataset



Variable:

Es una característica que puede tomar distintos valores

(ej: edad, ingresos, categoría de cliente)

Tipos de variables:



Cualitativas (categóricas) No numéricas. Se dividen en:

→ **Nominal:** sin orden (ej: color, país, tipo de producto)

→ **Ordinal:** con orden (ej: nivel educativo, satisfacción, categoría)



Cuantitativas (numéricas)

Representan cantidades. Se dividen en:

→ **Discretas:** valores enteros (ej: cantidad de compras)

→ **Continuas:** valores en un rango (ej: peso, altura, tiempo)

“El tipo de variable define cómo podemos analizar los datos.”



¿Cuáles son los niveles de medición?

Cómo clasificamos la naturaleza de los datos:

● **Nominal:** Etiquetas sin orden (ej: género, color).

● **Ordinal:** Categorías con orden (ej: ranking, nivel de satisfacción).



Niveles métricos (Cuantitativos)



Intervalo: Distancias iguales, cero arbitrario (ej: temperatura en °C, año).



Razón: Cero absoluto indica ausencia (ej: altura, peso, ingresos).

“El nivel de medición dicta las operaciones estadísticas válidas.”

Población vs Muestra

¿A quién representan nuestros datos? No siempre podemos analizar todo... y ahí aparece la muestra



Población

Conjunto total de elementos que queremos estudiar

(ej: todos los clientes de una empresa)



Muestra

Subconjunto de la población que analizamos

(ej: clientes del último mes)

Ejemplo: Queremos analizar el comportamiento de compra

Población: todos los clientes históricos

Muestra: clientes de este mes

Idea clave: Siempre trabajamos con muestras → porque no siempre tenemos todos los datos → o sería muy costoso analizarlos

“Toda muestra introduce incertidumbre.”

Medidas de Tendencia Central: Media, Mediana, Moda

Media (Promedio Aritmético)

Definición: La suma de todos los valores **dividida** por la cantidad total de observaciones.

Ejemplo:
 $(2+3+5+5+7)/5 = 22/5 = 4.4$

Mediana

Definición: El valor central en un conjunto de datos ordenado. Divide los datos en **dos mitades iguales**.

Ejemplo (ordenado):

2, 3, **5**, 5, 7.


La mediana es 5.



Moda

Definición: El valor que aparece con mayor frecuencia en el conjunto de datos.

Ejemplo:
2, 3, **5**, **5**, 7.
La moda es 5.



Idea clave: Estas medidas resumen el centro de los datos, pero cada una ofrece una perspectiva diferente. ¡La elección depende de la distribución y los outliers!

“Elegir la medida adecuada depende de la distribución de los datos y la pregunta que queremos responder.”

Media: el promedio de toda la vida

$$x = (x_1 + x_2 + \dots + x_n) / n$$

Ejemplo: notas de 5 alumnos

Alumno	Nota
A1	6
A2	7
A3	8
A4	9
A5	5

$$\text{Media} = (6 + 7 + 8 + 9 + 5) / 5 = 35 / 5 = 7$$

Problema: es sensible a los outliers

Si el alumno A5 saca 0 en lugar de 5:

$$\text{Media} = (6 + 7 + 8 + 9 + 0) / 5 = 30 / 5 = 6$$

Un solo valor extremo baja toda la media. Eso es el efecto de los outliers.

Mediana: el valor del medio

Para calcularla: ordena los datos de menor a mayor y toma el valor central.

n impar (5 datos)

Datos: 3, 7, 5, 9, 4

Ordenados: 3 4 [5] 7 9

Mediana = 5 (el tercer valor)

La posición es: $(n + 1) / 2 = (5 + 1) / 2 = 3$

n par (6 datos)

Datos: 3, 7, 5, 9, 4, 6

Ordenados: 3 4 [5 6] 7 9

Mediana = $(5 + 6) / 2 = 5.5$

Promedio de los dos valores centrales.

La mediana no se inmuta ante outliers — por eso decimos que es una medida ROBUSTA.

Moda: el valor que más se repite

La moda es el único estadístico que funciona con variables CATEGÓRICAS.

Variable numérica

Datos: 3, 5, 3, 7, 3, 9, 5

Moda = 3 (aparece 3 veces)

Variable categórica

Datos: rojo, azul, rojo, verde, rojo

Moda = rojo (aparece 3 veces)

Bimodal

Datos: 2, 3, 3, 5, 5, 7

Modas = 3 y 5 (ambas aparecen 2 veces)

Cuando usar cada una

Moda: variables categóricas o cuando quieres saber el valor más común. *No tiene sentido calcular media o mediana sobre 'rojo/azul/verde'.*

¿Cómo resumimos muchos datos en pocos números?




De datos crudos a información útil

El Problema y el Ejemplo

Problema: Tenemos muchos datos... ¿cómo los resumimos para entender qué está pasando?

Ejemplo Notas de un examen:



Resumen con medidas clave:

- ✦ **Media** (promedio) → valor “promedio” de todos los datos
- ✦ **Mediana** → valor central al ordenar los datos
- ✦ **Moda** → valor que más se repite

¿Qué pasa con valores extremos?

Ejemplo:

4, 6, 6, 7, 8, 8, 9, 10, 100

- la media cambia significativa no
- la mediana casi permanece más estable

Idea clave: Cada medida cuenta una historia distinta sobre los datos

“Resumir datos no es simplificar... es interpretar.”

¿Qué es un Outlier (Valor Atípico)?

 Datos que se salen de la norma

Definición

Es un punto de dato que difiere significativamente del resto de las observaciones. Es una anomalía o un valor extremo en el conjunto de datos.

Ejemplo Visual



Ejemplo de la Vida Real

Contexto: Edades en una clase de jardín de infantes.

Datos: 4, 5, 4, 5, 4, 35 (la maestra)

El valor "35" es un outlier claro.

Idea clave: Los outliers pueden distorsionar el promedio (media), pero suelen tener poco efecto en la mediana. ¡Es crucial identificarlos!

"Un solo dato extremo puede cambiar toda la historia si no se detecta."

Como un valor extremo cambia todo... o casi todo

Dataset de salarios mensuales (en pesos, 5 personas):

Sin outlier

Datos:

\$ 60.000, \$ 65.000, \$ 70.000, \$ 72.000, \$ 68.000

Media: **\$ 67.000**

Mediana: **\$ 68.000**

Media y mediana son parecidas. Los datos son homogéneos.

Con outlier (CEO se une)

Datos:

\$ 60.000, \$ 65.000, \$ 70.000, \$ 72.000, \$ 1.800.000


Media: **\$ 413.400**

Mediana: **\$ 68.000**

La media se disparó x6. La mediana no se movió. ¿Cual representa mejor al grupo?

Dividir los datos en partes iguales

Un percentil P indica que el P% de los datos está por debajo de ese valor.



IQR = Q3 - Q1 (contiene el 50% central de los datos)

P10 El 10% de los datos está por debajo de este valor. En notas: sería el 10% de los alumnos con peores resultados.

P50 La mediana. El 50% está por debajo. Divide el conjunto exactamente al medio.

P90 El 90% está por debajo. En ingresos: estar en P90 significa ganar más que el 90% de la población.

Todo esto en Python con pandas

```
import pandas as pd

df = pd.read_csv('datos.csv')

# Resumen completo: count, mean, std, min, max, Q1, Q2, Q3
df['salario'].describe()

# Medidas de centro por separado
df['edad'].mean()      # media
df['edad'].median()    # mediana
df['ciudad'].mode()[0] # moda (primer valor si hay varios)

# Percentiles
df['salario'].quantile([0.10, 0.25, 0.50, 0.75, 0.90])

# Tipo de cada columna
df.dtypes

# Ver valores únicos (para categóricas)
df['nivel_edu'].value_counts()
```

Tip: describe() te da los cuartiles (Q1=25%, Q2=50%, Q3=75%). Es el primer comando que vas a ejecutar en cualquier proyecto.

Trabajamos variables ordinales con pd.categorical en pandas

```
import pandas as pd

# Datos
df = pd.DataFrame({
    'peso': ['pesado', 'liviano', 'mediano', 'liviano', 'pesado']
})

# Definir categorías ordenadas

df['peso'] = pd.Categorical(
    df['peso'],
    categories=['liviano', 'mediano', 'pesado'],
    ordered=True
)

df_ordenado = df.sort_values('peso')
```

</> Python

	peso
1	liviano
3	liviano
2	mediano
0	pesado
4	pesado

Por qué todo esto importa en Machine Learning

1

Tipos de variables → que modelo elegir

Variables numéricas pueden ir a regresión lineal. Variables categóricas necesitan codificación (dummies) o árboles. La escala determina si necesitas normalizar.

2

Outliers → distorsionan el entrenamiento

Un outlier en el target puede hacer que el modelo aprenda un patrón incorrecto. Deben detectarse antes de entrenar.

3

Media vs Mediana → imputación de faltantes

Cuando hay valores faltantes (NaN), ¿con que los reemplazas? Si hay outliers, la mediana es más segura que la media.

4

Percentiles → detectar rangos válidos

Si el 99% de los precios está entre \$100 y \$10.000 y aparece un dato de \$5.000.000, seguramente es un error. Los percentiles ayudan a definir límites razonables.