

UNIDAD 1 · CLASE 2

Estadística descriptiva II

Dispersión, outliers y la regla del 68-95-99.7

Modulo II · Ciencia de Datos e Introducción a Machine Learning

Qué vamos a ver hoy

1

Varianza y desvío estándar

Cuánto se alejan los datos del promedio

2

Rango intercuartil (IQR)

Una medida robusta frente a outliers

3

Regla 68-95-99.7

Lo que esconde la distribución normal

4

Z-score

Cuántos desvíos estás del promedio

5

Detección de outliers

Cuándo eliminar y cuándo conservar

6

Boxplot

Toda la dispersión de un vistazo

Pero antes... ¿qué vimos la clase pasada?

Media

Promedio aritmético. Se ve afectada por valores extremos.

Mediana

El valor del medio. Resiste a los outliers.

Moda

El valor más frecuente. Útil para variables categóricas.

Bien. Ya sabemos describir el CENTRO de los datos.

Hoy vamos a medir QUÉ TAN DISPERSOS están.

ENTENDIENDO EL SESGO EN LOS DATOS (SKEWNESS)

DATOS SIMÉTRICOS (SIN SESGO)


La “cola” es igual en ambos lados.
La Media, Mediana y Moda coinciden.



La mayoría de los valores están cerca del centro. El promedio es una buena representación.

SESGO POSITIVO (DERECHA)

La “cola” se extiende hacia valores altos. $\text{Media} > \text{Mediana} > \text{Moda}$.




Pocos valores muy altos alejan la media del centro. La mayoría de los datos son bajos.



Ejemplos Comunes:
Salarios,
Precios de viviendas.

SESGO NEGATIVO (IZQUIERDA)

La “cola” se extiende hacia valores bajos. $\text{Media} < \text{Mediana} < \text{Moda}$.



Pocos valores muy bajos alejan la media hacia abajo. La mayoría de los datos son altos.

Ejemplos Comunes:
Notas de exámenes,
Edad de jubilación.


Dos cursos, misma media... ¿son iguales?

Curso A

Notas: 6.5, 7, 7, 7, 7.5

Media: 7

Casi todos sacaron 7. Predecible.




Curso B

Notas: 2, 4, 7, 10, 12 (normalizadas)

Media: 7

Todo el espectro. Mucha incertidumbre.



Varianza y Desvío Estándar: Poblacional vs Muestral

Poblacional (σ^2)

Promedio de los cuadrados de las distancias de cada dato a la media.

$$\sigma^2 = \sum (x_i - \mu)^2 / N$$

Muestral (s^2)

- Aproximación para muestras. Usa el estimador de corrección de Bessel (N-1)

$$s^2 = \sum (x_i - \bar{x})^2 / (n - 1)$$

⚠ Problema:

Las unidades quedan al cuadrado. Si las notas iban de 0 a 10, la varianza está en "notas²". Cuesta interpretar.

Desvío estándar (σ)

Raíz cuadrada de la varianza. Vuelve a las unidades originales.

$$\sigma = \sqrt{\sigma^2}$$

Muestral (s)

- Raíz cuadrada de la varianza muestral. Vuelve a las unidades originales

$$s = \sqrt{s^2}$$

✓ Lo bueno:

Se lee igual que los datos. "Las notas son 7 ± 1.5 " significa que típicamente están entre 5.5 y 8.5.


Comparativa de Fórmulas: $\sigma^2 = \sigma^2$ $\sigma = s^2$

σ^2 — poblacional de la cuadrado, desvío muestral
 s — muestral de la editada, cierto muestral

Lógica de la Varianza

La varianza representa el **promedio de los cuadrados** de las desviaciones. Es fundamental en estadística inferencial y modelos predictivos.

- ✓ **Sensibilidad:** Muy sensible a valores atípicos (outliers).
- ✓ **Unidades:** Siempre en unidades cuadráticas (ej. m^2 , $\2).
- 📊 **Propiedad:** Siempre es un valor no negativo (≥ 0).



De Varianza a Desviación

La desviación estándar es simplemente la raíz cuadrada de la varianza,
lo que "deshace" el cuadrado previo.

$$\sigma = \sqrt{\sigma^2}$$

¡Ahora las unidades son las mismas que tus datos!

Si los datos son normales, vale la regla 68-95-99.7

En distribuciones normales:


68% dentro de 1 desvío.

95% dentro de 2 desvíos.

99.7% dentro de 3 desvíos.

Si un dato está a **más de 3 desvíos**, es un outlier probable.

REGLA EMPÍRICA



ESTANDARIZACIÓN: Z-SCORE

Z

¿Cuántos desvíos estás del promedio?

$$z = \frac{x - \mu}{\sigma}$$

Interpretación para ML

Permite comparar variables con diferentes escalas (ej: Edad vs Salario).

- ✓ • **z = 0**: Valor igual a la media.
- ✓ • **|z| = 1**: A un desvío (normal).
- **|z| > 3**: Outlier (extremadamente raro).

Es la base de StandardScaler en Scikit-Learn.



Z-score: cuántos desvíos estás del promedio

$$z = (x - \mu) / \sigma$$

$$z = 0$$

Estás exactamente en la media

$$|z| = 1$$

Estás a un desvío. Normal.

$$|z| > 3$$

Outlier. Algo raro pasa.

→ *En ML: estandarizar (z-score) es la operación preferida para que todas las variables "pesen" parecido en el modelo. StandardScaler hace exactamente esto.*

Por qué a Machine Learning le importa el desvío

Imaginate que entrenás un modelo con dos variables:

- edad → valores entre 0 y 100 (desvío ≈ 15)
- salario → valores entre 0 y 5.000.000 (desvío ≈ 800.000)

El modelo va a pensar que el salario "importa más" sólo porque sus números son grandes.

Solución: estandarizar.

Restar la media y dividir por el desvío → todas las variables quedan en la misma escala. Eso es lo que hace StandardScaler en scikit-learn.

Detectar outliers: dos métodos

Método 1 · Z-score

Si $|z| > 3 \rightarrow \text{outlier}$

Asume que los datos son aproximadamente normales.
Sensible al propio outlier (porque entra en el cálculo de la media).

Método 2 · IQR

Fuera de $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$

No asume normalidad. Es el criterio que usa el boxplot. Más robusto que el z-score cuando hay datos asimétricos.

¿Eliminarlos siempre? NO.


Un outlier puede ser un error de medición (eliminar) o un evento real importante: un fraude, un alumno con beca, un día de tormenta. Antes de borrarlo, enténdelo.

ESTADÍSTICA: MÉTODOS DE DETECCIÓN DE OUTLIERS

MÉTODO: RANGO INTERCUARTÍLICO (IQR / RIC)

MÉTODO DEL RANGO INTERCUARTÍLICO (IQR)

Métrica de Dispersión Central



REGLA DEL 1.5 x IQR

Vallas Inferior (Límite) Vallas Superior (Límite)

$$Q1 - 1.5 * IQR$$

$$Q3 + 1.5 * IQR$$

Outliers Detectados

Outliers Detectados


RESUMEN Y USO

Robusto contra valores extremos, ideal para distribuciones no normales.

MÉTODO: Z-SCORE (PUNTUACIÓN Z)

MÉTODO Z-SCORE

Métrica de Posición Relativa



CÁLCULO Z-SCORE

$$Z = \frac{(X - \mu)}{\sigma}$$

REGLA COMÚN

$$|Z| > 3$$

Detección de Outlier

RESUMEN Y USO

Sensible a la media y desviación estándar, ideal para distribuciones normales o casi normales.

IMPACTO DE LA DISPERSIÓN

Visualización de la variabilidad en diferentes conjuntos de datos con la misma media:



A mayor porcentaje, mayor es el riesgo o la incertidumbre sobre el comportamiento del valor promedio.

Anatomía Visual de un Boxplot

Componentes Clave

Caja

Contiene el 50% central de los datos (IQR).

Línea Central


Representa la Mediana del conjunto.

Bigotes

Rango de datos "normales" (no outliers).

Puntos

Outliers detectados fuera de los límites calculados.



* Si los datos son normales, el boxplot es simétrico. Si no, se verá "estirado".

Cómo crear un Boxplot con Seaborn

CÓDIGO


Snippet de Código

```
import seaborn as sns
import pandas as pd
import matplotlib.pyplot as plt
# Cargar datos (ejemplo Titanic)
df = sns.load_dataset("titanic")
# Crear el boxplot
ax = sns.boxplot(x=df['age'], palette='Set3')
# Personalizar (opcional)
ax.set_title("Distribución de Edad por Seaborn")
ax.set_xlabel("Edad")
# Mostrar
plt.show()
```

- Cargar librerías necesarias.
- **sns.load_dataset:** Obtiene un DataFrame de ejemplo.
- **sns.boxplot:** Es la función principal para el gráfico. Se define `x='` (para una variable) o `x` e `y`` (para dos).
- **Personalización:** Seaborn permite usar paletas (palette) y matplotlib permite personalizar etiquetas y títulos (ax.set_...).

RESULTADO VISUAL

Gráfico Generado



- **Integración con Pandas:** Utiliza DataFrames directamente.
- **Estilo Automático:** Aplica temas visuales por defecto.
- **Soporte Multivariado:** Fácil de añadir categorías adicionales.

DETECCIÓN DE OUTLIERS EN ACCIÓN


¿Por qué el Boxplot es mejor?

A diferencia del Z-score, el Boxplot (método IQR) **no asume** que los datos siguen una distribución normal.



¿Eliminarlos siempre? NO.

Pueden ser errores de carga o eventos reales críticos (ej: fraudes bancarios).



Source: Leadup Collective, Boxplot (médocus IQR) "follow the flock" 2014). (2007:-256).

Calculando varianza y desvío muestral en python

```
import pandas as pd
import statistics as stats

# Datos de ejemplo
datos_lista = [10, 12, 18, 15, 14, 22, 11]
df = pd.DataFrame({'valores': datos_lista})

# --- CON STATISTICS (Nativo) ---
var_stats = stats.variance(datos_lista) # Varianza
std_stats = stats.stdev(datos_lista) # Desvío

# --- CON PANDAS ---
var_pandas = df['valores'].var()
std_pandas = df['valores'].std()
```

Nota Técnica

Para varianza **poblacional** (N):

- `stats.pvariance()`
- `stats.pstdev()`
- `.var(ddof=0)` en pandas

Calculando quantiles en pandas y statistics

```
# --- CON STATISTICS ---  
# La función quantiles() corta los datos por defecto en 4 partes (cuartiles)  
cuartiles_stats = stats.quantiles(datos_lista, n=4)  
# Devuelve una lista con 3 valores: [Q1, Q2 (Mediana), Q3]  
  
# Si quisieras deciles (10 partes), cambias a n=10  
deciles_stats = stats.quantiles(datos_lista, n=10)  
  
# --- CON PANDAS ---  
# En pandas usas la función quantile() indicando la posición exacta en un float entre 0 y 1  
q1_pandas = df['valores'].quantile(0.25)  
q2_pandas = df['valores'].quantile(0.50) # Mediana  
q3_pandas = df['valores'].quantile(0.75)  
  
# También puedes pasarle una lista para obtener varios a la vez:  
cuartiles_pandas = df['valores'].quantile([0.25, 0.5, 0.75])
```

Nota: `pandas` ignora automáticamente valores faltantes. `statistics` puede arrojar un error si encuentra datos nulos.

Todo esto en Python (con pandas y seaborn)

```
import pandas as pd
import seaborn as sns

df = pd.read_csv('titanic.csv')

# Resumen completo: cuenta, media, desvío, min/max, cuartiles
df['Age'].describe()

# Métricas sueltas
df['Age'].var()          # varianza
df['Age'].std()          # desvío estándar
df['Age'].quantile([0.25, 0.5, 0.75])  # cuartiles

# Z-score
z = (df['Age'] - df['Age'].mean()) / df['Age'].std()
outliers = df[z.abs() > 3]

# Boxplot rápido - visualizamos usando un gráfico boxplot
sns.boxplot(x=df['Age'])
```

Cuándo usar qué medida

Si querés...	Usá esta medida	Por qué
Describir el centro (datos típicos)	Media	Funciona bien cuando no hay outliers extremos
Describir el centro (con outliers)	Mediana	No se deja arrastrar por valores extremos
Medir dispersión general	Desvío estándar	Mismas unidades que los datos, base de muchos métodos
Medir dispersión robusta	IQR	Ignora el 25% inferior y superior, ideal con outliers
Detectar outliers (datos normales)	Z-score ($ z > 3$)	Usa la regla 68-95-99.7
Detectar outliers (datos asimétricos)	IQR + boxplot	No asume distribución normal

Preguntas

1 Si dos cursos tienen la misma media pero distintos desvíos, ¿en cuál preferirías predecir la nota de un alumno nuevo?

→ En el de menor desvío: ahí los datos son más predecibles.

2 ¿Por qué el IQR se considera una medida "robusta"?

→ Porque se calcula sólo con el 50% central de los datos, así que los valores extremos no lo afectan.

3 Un alumno tiene $z\text{-score} = 2.4$ en una prueba. ¿Es outlier?

→ No (por la regla del 3). Pero está claramente por encima del promedio (≈ 2 desvíos).

4 Si tus datos NO son normales, ¿qué método de detección preferís: $z\text{-score}$ o IQR?

→ IQR, porque no asume normalidad.