

Correlación y relaciones

Pearson, Spearman y por qué correlación $\neq$ causalidad

Modulo II · Ciencia de Datos e Introducción a Machine Learning



[Descargar la notebook con ejemplos](#)



[Ver el video de la clase](#)

01

Relaciones de
Datos

02

Pearson y
Spearman

03

Correlación $\neq$
Causalidad

04

Cuarteto de
Anscombe

05

Multicolinealidad

06

Python y
Conclusiones

Covarianza: Introducción

Entendiendo cómo dos variables varían juntas



- **Definición intuitiva:** La covarianza nos dice si, en general, los valores altos de una variable se corresponden con los valores altos de la otra (positiva), o si los valores altos se corresponden con los bajos (negativa).

$$f = \frac{1}{n}$$


- **Expresión Matemática Simplificada:** Muestra una limpia versión conceptual de $Cov(X, Y) = \frac{\sum (X_i - \mu_X)(Y_i - \mu_Y)}{n-1}$.





- **Interpretación del valor:** El valor es difícil de interpretar por sí solo. Depende de las unidades de medida original de las variables.



- **Su relación con la Correlación:** La correlación es simplemente la covarianza normalizada por las desviaciones estándar, haciendo el valor comparable (-1 a 1).



Coeficientes Pearson y Spearman



Introducción a la Correlación de Pearson

Definición formal y cálculo de la relación lineal.


= • Pearson's r mide la fuerza y dirección de una relación lineal.

$\sum x$ •  Se basa en la covarianza de las variables originales.

  Indica la bondad de ajuste de una línea recta.

 Útil cuando se cumplen los supuestos de linealidad y normalidad.

ANÁLISIS DE LA CORRELACIÓN DE PEARSON (r)



ESCALA DE INTERPRETACIÓN DE r

-1.0	-0.9 a -0.7	-0.6 a -0.4	-0.3 a -0.1	0.0	0.1 a 0.3	0.4 a 0.6	0.7 a 0.9	+1.0
Perfecta Negativa	Alta Negativa	Moderada Negativa	Débil Negativa	Nula	Débil Positiva	Moderada Positiva	Alta Positiva	Perfecta Positiva

ESCALA DE INTERPRETACIÓN DE r

Pearson: El Coeficiente Lineal (r)


Midiendo la relación lineal entre variables



Mide cuán fuerte y en qué dirección es la relación lineal entre dos variables numéricas continuas.

1. Fuerte Correlación Positiva


$r \approx 0.9$ | Suben juntas



$r \approx 0.9$ | Suben juntas

2. Fuerte Correlación Negativa


$r \approx -0.9$ | Una sube, la otra baja



$r \approx -0.9$ | Una sube, la otra baja

3. Sin Correlación Lineal

$r \approx 0.0$ | No hay patrón



$r \approx 0.0$ | No hay patrón

1. Correlación Positiva Fuerte

- $r \approx 0.85$
- Años de experiencia vs. Salario (en una industria estable)
- A más años trabajados, mayor tiende a ser el salario.

2. Correlación Negativa Fuerte

- $r \approx -0.92$
- Velocidad de un auto vs. Tiempo de viaje (distancia fija)
- A mayor velocidad, menor tiempo requerido para completar el viaje.

3. Correlación Débil / Nula

- $r \approx 0.15$
- Consumo de café vs. Inteligencia
- No hay relación predecible lineal entre estas variables.

EJEMPLO DE CÁLCULO

Correlación de Pearson: Tabla de Datos

	x	y	$x - \bar{x}$	$y - \bar{y}$	$(x - \bar{x})(y - \bar{y})$	$(x - \bar{x})^2$	$(y - \bar{y})^2$
1	20.0	30.0	-2.0	-15.0	30.0	4.0	225.0
2	40.0	60.0	18.0	15.0	270.0	324.0	225.0
3	20.0	40.0	-2.0	-5.0	10.0	4.0	25.0
4	30.0	60.0	8.0	15.0	120.0	64.0	225.0
5	10.0	30.0	-12.0	-15.0	180.0	144.0	225.0
6	10.0	40.0	-12.0	-5.0	60.0	144.0	25.0
7	20.0	40.0	-2.0	-5.0	10.0	4.0	25.0
8	20.0	50.0	-2.0	5.0	-10.0	4.0	25.0
9	20.0	30.0	-2.0	-15.0	30.0	4.0	225.0
10	30.0	70.0	8.0	25.0	200.0	64.0	625.0
Total	220.0	450.0	0.0	0.0	900.0	760.0	1850.0

2. Resumen Estadístico Detallado

$$\bar{x} = 22 \mid \bar{y} = 45$$

$$\Sigma(x_i - \bar{x})(y_i - \bar{y}) = 900$$

$$\Sigma(x_i - \bar{x})^2 = 760$$

$$\Sigma(y_i - \bar{y})^2 = 1850$$

$$r = 0.759$$


Cálculo:

$$r = \frac{\Sigma(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\Sigma(x_i - \bar{x})^2 \Sigma(y_i - \bar{y})^2}}$$

$$r = \frac{900}{\sqrt{760 + 1850}}$$

$$r = \frac{900}{1185.75}$$

$$r = 0.759$$



Conclusión: Correlación Positiva Fuerte

A mayor cantidad de llamadas → mayor volumen de ventas.




Introducción a la Correlación de Spearman

Análisis de datos de rango y relación monótona, con un enfoque en la fuerza y dirección.

La correlación de Spearman analiza la fuerza y dirección de la relación monótona entre dos variables.

No requiere linealidad, solo monotonidad.

Permite predecir tendencias ordenadas basándose en los rangos de los datos.



NOTA IMPORTANTE: COMPRENDIENDO LA FUERZA Y DIRECCIÓN

FUERZA (Magnitud):

- Se determina por el valor absoluto del coeficiente ρ (ro), desde 0 (Nula) a 1 (Perfecta).
- Indica que tan cercanos están los rangos de las variables a una relación monótona perfecta.
- Más cerca de 1, más fuerte; más cerca de 0, más débil.

DIRECCIÓN (Signo):

- Positiva (+):** Los rangos aumentan juntos. A medida que **X** (rango) sube, **Y** (rango) sube.
- Negativa (-):** Los rangos se mueven inversamente. A medida que **X** (rango) sube, **Y** (rango) baja.

Ejemplo Práctico: Cálculo de Correlación de Spearman

1. Tabla de Datos y Cálculo de Rangos

Persona 	Días (X) 	Vistas Totales (Y) 	Rango X (r_x)	Rango Y (r_y)	d ($r_x - r_y$)	d^2
A	1	10	1	1	0	0
B	2	100	2	2	0	0
C	3	1,000	3	3	0	0
D	4	10,000	4	4	0	0
					Σ	0

2. Resumen Estadístico y Fórmula

$$N = 4$$

$$\Sigma d^2 = 0$$

$$\rho = 1 - \frac{6 \Sigma d_i^2}{n(n^2 - 1)}$$

$$\rho = 1 - \frac{6 * 0}{4(4^2 - 1)}$$

$$\rho = 1 - \frac{0}{4 * 15}$$

$$\rho = 1 - 0$$

$$\rho = 1.0$$

Conclusión: Correlación Positiva Perfecta

Se observa una relación monótona perfecta: a medida que pasan los días, las vistas aumentan de forma exponencial.

El 'Error' de Pearson: Por Qué No Sirve Aquí

Comparación de la dispersión y los coeficientes usando el dataset exponencial.

1. La Suposición de Pearson




Pearson busca una **LÍNEA RECTA** perfecta



Pearson asume que por cada día, las vistas deben **subir de forma constante**



Pearson asume **ruido** en los primeros 4 días y ve el **Día 5** como un **valor atípico** desproporcionado



2. Resultado y Veredicto Correcto

- Si aplicas Pearson: $r \approx 0.60$ (moderada/débil)
- Si añades más días (exponenciales): $r \approx 0.45$ (débil)

Veredicto de Pearson: **Falsa**

Pearson te dirá que la relación es **moderada o débil**. Pero la relación entre los días y el éxito del video es **ABSOLUTA Y PERFECTA**, solo que no es lineal.



Pearson



Spearman

Resumen de Diferencias: Pearson vs. Spearman

Característica	Pearson (Lineal)	Spearman (Rangos)
Relación medida	Lineal	Monotónica
Trabaja sobre	Valores originales	Rangos (posiciones)
Sensible a outliers	Sí	No (es robusto)
Requiere normalidad	Sí (recomendado)	No
Tipo de variables	Cuantitativas continuas	Cuantitativas u ordinales



Conclusión: $r_s = 0.80$ indica una correlación monotónica positiva muy fuerte, pero imperfecta. Mayor rango en X tiende a asociarse con mayor rango en Y, con ligeras variaciones.

CORRELACIÓN $\neq$ CAUSALIDAD

Que dos variables se muevan juntas NO significa que una cause la otra.



Helados y ahogamientos

Cuando aumentan las ventas de helado, aumentan los ahogamientos en piletas. ¿El helado provoca ahogamientos? No: ambos suben con el calor.



Tamaño de zapato y vocabulario

Niños con pies más grandes saben más palabras. ¿Los pies grandes te hacen más culto? No: ambos crecen con la edad.



Paraguas y lluvia

Días con muchos paraguas → llueve más. ¿Los paraguas causan lluvia? No: la gente saca paraguas PORQUE va a llover.

EL CUARTETO DE ANSCOMBE


La importancia crítica de visualizar los datos antes del análisis estadístico.



- Un conjunto de cuatro bases de datos que tienen idénticas estadísticas sumarias (media, varianza, correlación).



- Fueron creadas para demostrar que los estadísticos resúmenes pueden ocultar patrones de datos drásticamente diferentes.



- A primera vista, parecen indistinguibles para un análisis puramente numérico.



- La lección clave: No se puede confiar solo en números resumidos; la visualización es esencial.


CONSEJO DE ANÁLISIS: LECCIÓN DE ANSCOMBE

- **Paso 1:** Revisa las estadísticas sumarias básicas.
- **Paso 2:** Genera diagramas de dispersión y boxplots.
- **Paso 3:** Integra ambas perspectivas antes de concluir.
- **Principio:** Los números dicen mucho, pero los gráficos lo dicen todo sobre la forma.

ANÁLISIS COMPARATIVO DEL CUARTETO

MISMOS ESTADÍSTICOS SUMARIOS PARA TODOS (n=11):

	Dataset I	II	III	IV
Media de x ($\bar{x}$)	7.50	7.50	7.50	7.50
Varianza de x	~3.76	~3.76	~3.76	~3.76
Media de y ($\bar{y}$)	~7.50	~7.50	~7.50	~7.50
Varianza de y	~4.12	~4.12	~4.12	~4.12
Correlación r	0.82 (Fuerte)			
Regresión lineal $\hat{y}$	$y = 3 + 0.5x$			



MULTICOLINEALIDAD


¿QUÉ ES?



- **Definición:** Fenómeno en el que dos o más variables predictoras en un modelo están fuertemente correlacionadas.



- **Información redundante:** Significa que las variables cuentan “la misma historia”.




- **Ejemplo claro:** Edad vs. Experiencia laboral (en la mayoría de los casos).

CONSECUENCIAS



Dificulta la interpretación del impacto de cada variable.



Reduce la precisión de los coeficientes del modelo.



Afecta la capacidad de predicción del modelo en nuevos datos.

¿CÓMO DETECTARLA Y MANEJARLA?

- **DETECCIÓN:** Matriz de correlación (ver imagen_2.png).
- **MANEJO:** Eliminar variables redundantes, combinar características (PCA) o usar modelos robustos.

Matriz de correlación: ver todo de un vistazo

- **Una tabla cuadrada**
- Cada celda es la correlación entre dos variables. La diagonal siempre vale 1 (cada variable se correlaciona perfectamente consigo misma).
- **`df.corr()`**
- *Te devuelve la matriz en pandas.*

Ejemplo de Matriz de Correlación


	Edad	Salario	Años exp.
Edad	1.00	0.68	0.91
Salario	0.68	1.00	0.74
Años exp.	0.91	0.74	1.00

Color = intensidad de la correlación

Heatmap: Visualización intuitiva de correlaciones

En datasets con múltiples variables, una matriz numérica es difícil de interpretar. El heatmap utiliza el **COLOR** para revelar patrones de correlación de forma instantánea:


-  **Rojo intenso:** Indica una fuerte correlación positiva (próxima a +1).
-  **Azul intenso:** Indica una fuerte correlación negativa (próxima a -1).
-  **Color pálido:** Muestra una correlación débil o nula (cerca de 0).



```
sns.heatmap(df.corr(), annot=True, cmap='coolwarm',  
             cmap='coolwarm', vmin=-1,  
             vmax=1)
```

- `annot=True` muestra el valor numérico en cada celda.
- `cmap='coolwarm'` aplica la paleta clásica de gradiente (azul → rojo).

Heatmap triangular: Maximizando la eficiencia visual




- **Reduce el desorden visual:** Elimina la información duplicada de la diagonal y el triángulo superior.



- **Mejora la legibilidad:** Facilita la interpretación al enfocar la vista en relaciones únicas, especialmente en matrices grandes (>10 variables).



- **Enfatiza relaciones clave:** Hace más evidentes los patrones de correlación más fuertes y débiles.



```
import numpy as np
# Crear máscara triangular superior
mask = np.triu(np.ones_like(matriz, dtype=bool))
sns.heatmap(matriz, mask=mask, annot=True,
             cmap='coolwarm', vmin=-1, vmax=1)
plt.show()
```

PROBLEMA

Multicolinealidad: cuando dos features cuentan lo mismo

Si dos variables están muy correlacionadas ($r > 0.8$) entre sí, le estás pasando al modelo información redundante.



Matriz

Calcular la matriz de correlación completa para todas las variables.



Identificar

Buscar pares con una correlación superior a 0.8.



Comparar

Comparar la correlación de cada feature redundante con el target.



Eliminar

Eliminar la feature con menor correlación predictiva con el target. El target es la variable que queremos predecir.

Correlación en Python

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

# Correlación entre dos columnas (Pearson por defecto)
df['Age'].corr(df['Fare']) # Pearson
df['Age'].corr(df['Fare'], method='spearman') # Spearman

# Matriz de correlación completa
matriz = df.corr(numeric_only=True)

# Heatmap
sns.heatmap(matriz, annot=True, cmap='coolwarm',
            vmin=-1, vmax=1, fmt='.2f')
plt.show()

# Buscar pares muy correlacionados (multicolinealidad)
altos = matriz.abs() > 0.8
```

Probate

1

Un analista observa una correlación muy alta entre el consumo de chocolate y el nivel de inteligencia en diferentes países.
¿Cuál es la conclusión más rigurosa desde la ciencia de datos?

→ *Correlación no implica causalidad.*

2

¿Cuál es la diferencia principal entre Pearson y Spearman respecto al tipo de variables?

→ *Pearson requiere variables cuantitativas continuas; Spearman admite cuantitativas u ordinales.*

3

Si tiene dos variables con una relación curva pero siempre ascendente (monotónica), y obtiene un coeficiente de Pearson de 0.60 y uno de Spearman de 0.95, ¿por qué ocurre esta diferencia?

→ *Pearson se confunde con las relaciones no lineales y subestima la fuerza de asociación.*

4

¿Qué te enseña el cuarteto de Anscombe?

→ *Que dos datasets pueden tener el mismo r pero formas totalmente distintas. Hay que MIRAR el scatter, no confiar sólo en el número.*

Probate

5

Si se desea medir la relación entre dos variables donde una de ellas es ordinal (como un ranking de satisfacción) y existen valores atípicos, ¿cuál es el coeficiente más adecuado?

→ *Coeficiente de Spearman.*

6

En un modelo de Machine Learning, se detecta que dos variables independientes tienen una correlación de $r=0.94$. ¿Qué problema representa esto para el modelo?

→ *Multicolinealidad.*

7

En el proceso de selección de características, si se encuentran dos variables con multicolinealidad, ¿qué criterio se sugiere en esta clase para eliminar una de ellas?

→ *Eliminar la variable que esté menos relacionada con el target.*