

UNIDAD 1 · CLASE 5

Distribuciones de probabilidad

Distribuciones Uniforme, Normal, binomial y Poisson

Modulo II · Ciencia de Datos e Introducción a Machine Learning

[Notebook](#)

Qué vamos a ver hoy

1

Concepto

Variables aleatorias y la idea de probabilidad

3

Distribución Binomial

Contando éxitos en n intentos independientes

5

Distribución Normal y TLC

Campana de Gauss y el Teorema del Límite Central

2

Distribución Uniforme

Resultados con la misma probabilidad

4

Distribución de Poisson

Eventos por unidad de tiempo o espacio

6

Por qué a ML le importa

Modelos que asumen normalidad y probabilidad

DISTRIBUCIONES DE PROBABILIDAD · COMPARACIÓN DE LIBRERÍAS

¿Qué librería de Python usar para estadística y probabilidad?

Librería	Casos de Uso Principales	Fortalezas	Complejidad y Dependencias
statistics 	Estadística descriptiva básica y directa (media, mediana, desviación estándar, etc.) sin datos tabulares complejos.	Nativa (sin dependencias extra), extremadamente simple y ligera, ideal para cálculos rápidos sobre listas/datos simples.	Baja (solo listas/iterables). Cero dependencias externas.
 pandas	Análisis exploratorio de datos tabulares (DataFrames), limpieza, manipulación y agregaciones rápidas.	Integración total con manipulación de datos, rápida para agregaciones básicas en conjuntos de datos grandes.	Media (manejo de DataFrames). Depende de NumPy.
 SciPy 	Estadística inferencial avanzada, ajuste de distribuciones teóricas, tests estadísticos profundos, optimización.	Enorme variedad de distribuciones y pruebas, alta precisión científica, motor para cálculos complejos.	Alta (comprender parámetros de distribución, APIs complejas). Depende de NumPy y a veces pandas/matplotlib.

Distribución de Probabilidad

Una distribución de probabilidad describe cómo se distribuyen o reparten los posibles valores de una variable aleatoria y qué tan probable es observar cada uno de ellos.

Te dice: "¿qué tan probable es cada valor?"

Discretas

Toman valores contables: 0, 1, 2, 3...

Ej: cantidad de clientes en un día, número de caras al tirar moneda 10 veces.

Continuas

Toman cualquier valor en un rango.

Ej: la altura de una persona, el tiempo de respuesta de un servidor, la edad exacta.

DISTRIBUCIÓN UNIFORME

DISTRIBUCIÓN UNIFORME DISCRETA



Características:

- Resultados son valores distintos.
- Misma probabilidad para cada valor.




EJEMPLO:

- Lanzamiento de un dado equilibrado.
- Todos los números de una rifa.

$$P(X = x) = \frac{1}{N}$$

DISTRIBUCIÓN UNIFORME CONTINUA



Características:

- La **variable puede** tomar cualquier valor en un rango.
- Densidad constante.



EJEMPLO:

- Tiempo de espera para un autobús.
- Medición de temperatura en un rango.
- Punto de caída de un dardo.



$$f(x) = \frac{1}{b - a}$$

Distribución Binomial: contar éxitos



¿Qué modela?

Modela situaciones donde cada observación tiene solo dos resultados posibles:

- Éxito (sí)
- Fracaso (no)

¿Cuándo la usamos?


Cuando queremos responder preguntas como:

- ¿Cuántas veces ocurre un determinado evento en un número fijo de intentos?

Siempre que:

- Exista un número fijo de intentos (n).
- Cada intento tenga dos resultados posibles.
- Los intentos sean independientes.
- La probabilidad de éxito sea la misma en cada intento (p).

Binomial: $n=10$, $p=0.5$



Estadísticos:

Media (μ) = $np = 5$

Varianza (σ^2) = $np(1-p) = 2.5$

Idea Clave:

- La distribución binomial nos permite calcular la probabilidad de obtener una determinada cantidad de éxitos en un conjunto de intentos repetidos.

Ejemplos de uso de la Binomial



Éxito de un tratamiento

¿Cuántos pacientes responden favorablemente?

$n=1000$, $p=0.3$



Filtro de Spam

¿Cuántos de 100 correos recibidos son spam?

$n=100$, $p=0.45$



Conversión en la Web

¿Cuántos de 100 visitantes compran un producto?

$n=100$, $p=0.05$



Examen de Azar

¿Cuántos aciertos en 30 preguntas de V/F?

$n=30$, $p=0.5$

Binomial en Python: `scipy.stats.binom`



`pmf(k, n, p)` (Exacto)

Calcula la probabilidad de obtener **exactamente** k éxitos en n intentos repetidos.

Pregunta: ¿Cuál es la probabilidad de que EXACTAMENTE 5 clientes de 100 compren ($p=0.05$)?

```
import numpy as np
from scipy import stats
```

```
n = 100 # Número de intentos
p = 0.05 # Probabilidad de éxito
k = 5    # Cantidad de éxitos buscada
```

```
# Calcular probabilidad exacta de 5 éxitos
prob_pmf = stats.binom.pmf(k, n, p)
print(f"Prob. de exactamente {k} éxitos: {prob_pmf:.4f}")
# Resultado aproximado: 0.1800
```

parámetros:
 $n=100, p=0.05, k=5$



`cdf(k, n, p)` (Acumulado)

Calcula la probabilidad de obtener k o **menos** éxitos ($X \leq k$) en n intentos.

Pregunta: ¿Cuál es la probabilidad de que compren 5 clientes o MENOS ($n=100, p=0.05$)?


```
import numpy as np
from scipy import stats
```

```
n = 100 # Número de intentos
p = 0.05 # Probabilidad de éxito
k = 5    # Cantidad máxima de éxitos
```

```
# Calcular probabilidad acumulada de  $\leq 5$  éxitos
prob_cdf = stats.binom.cdf(k, n, p)
print(f"Prob. de {k} o menos éxitos: {prob_cdf:.4f}")
# Resultado aproximado: 0.6160
```

Distribución de Poisson: eventos por intervalo

Poisson: $\lambda = 3$



¿Cuándo la usamos?

Cuando contamos cuántas veces ocurre un evento en un intervalo fijo (de tiempo, espacio, etc.) y los eventos son raros e independientes.

Un solo parámetro:

λ (lambda): promedio de eventos por intervalo. Es a la vez la media y la varianza.

ejemplos de uso de Poisson

Llamadas por hora

Llegan a un call center en promedio 12 por hora.

Autos en peaje

Pasan ≈ 5 por minuto en hora pico.

Goles por partido

Promedio liga argentina ≈ 2.5 goles/partido.

Errores por página

En un libro técnico ≈ 0.3 typos por página.

Modelando eventos con poisson.pmf y cdf


PROBLEMA & CÓDIGO

Si a nuestro sitio web entran en promedio 3 usuarios por minuto ($\lambda = 3$), ¿cuál es la probabilidad de que entren exactamente 5 en el próximo minuto?

```
from scipy.stats import poisson

prob = poisson.pmf(k=5, mu=3) # En SciPy,
lambda se pasa como 'mu'
print(f'P(X=5) = {prob:.4f}') # P(X=5) ≈
0.1008
```

VISUALIZACIÓN & ASIMETRÍA




Observá cómo crece y se vuelve simétrica.

OTRA ÚTIL (cdf)

$P(X \leq 5)$: `poisson.cdf(k=5, mu=3)` (Prob. acumulada)

Distribución Normal: la campana de Gauss



μ : media (centro de la distribución)

σ : desviación típica (indica cuánto se alejan los valores de la media)

Surge frecuentemente cuando el fenómeno observado resulta de la suma de muchos factores pequeños e independientes.

Ejemplos en la vida real:

- Altura de la población
- Notas de un examen masivo
- Errores de medición
- Presión arterial

Los parámetros son μ y σ^2 .

Solo necesita dos números: μ y σ

μ (media)

Determina dónde está el CENTRO de la campana.

Si cambia μ , la campana se desplaza hacia la izquierda o derecha — pero mantiene la forma.

Ej: altura promedio en hombres ≈ 1.75 m

σ (desvío)


Determina QUÉ TAN ANCHA es la campana.

σ chico $\rightarrow$ curva alta y angosta (datos parecidos). σ grande $\rightarrow$ curva baja y ancha (datos dispersos).

Ej: desvío de altura ≈ 7 cm

La Regla 68-95-99.7 (Empírica)

The 68-95-99.7 Rule (Empirical Rule)



Distribución de los Datos:

- **68% de los datos:** Caen entre $\mu - \sigma$ y $\mu + \sigma$.
- **95% de los datos:** Caen entre $\mu - 2\sigma$ y $\mu + 2\sigma$.
- **99.7% de los datos:** Caen entre $\mu - 3\sigma$ y $\mu + 3\sigma$.

En una distribución normal, casi la totalidad de los valores se encuentran dentro de tres desviaciones típicas de la media.

Random variable X (deviation from the mean)

IMPORTANCIA DE LA NORMAL

¿Por qué la distribución normal es tan importante?

1

NATURALEZA APROXIMADAMENTE NORMAL:

Muchas variables reales presentan una forma similar a la campana de Gauss.

2


TEOREMA DEL LÍMITE CENTRAL (TLC):

Con muestras grandes, las medias muestrales tienden a la normalidad, sin importar la distribución original de los datos.

3

SIMPLIFICACIÓN MATEMÁTICA Y ESTADÍSTICA:

Facilita el cálculo de probabilidades, intervalos de confianza y pruebas de hipótesis. Es la base de la estadística inferencial.



La distribución normal es la herramienta central de la estadística porque aparece con frecuencia en la naturaleza y simplifica muchos procedimientos de análisis e inferencia.

Estandarización y scipy.stats.norm

¿Qué es el Z-Score?

Llevar cualquier distribución normal a una "Normal Estándar" ($\mu = 0$, $\sigma = 1$) mediante la fórmula:

$$Z = \frac{x - \mu}{\sigma}$$



Uso de scipy.stats.norm

Utilizada para calcular probabilidades bajo la curva (áreas).

```
from scipy.stats import norm

# Probabilidad de un valor menor a Z=1.96
porcentaje = norm.cdf(1.96)
```


stats.norm nos da varias funciones útiles:

- **pdf(x)** → densidad en x (no es probabilidad directa)
- **cdf(x)** → $P(X \leq x)$
- **ppf(q)** → el valor x tal que $P(X \leq x) = q$

¿Son normales tus datos?

1 DIAGNÓSTICO VISUAL RÁPIDO

```
import seaborn as sns
sns.histplot(data=df['col'], kde=True)
```



- Hací un histograma.
- Superponé la curva KDE (estimación de densidad).
- Si pegan, los datos se asemejan a una normal.

2 DIAGNÓSTICO FINO

```
import statsmodels.api as sm
sm.qqplot(df['col'], line='s')
```



- Crea un Q-Q plot.
- Compara tus datos con una normal teórica.
- Si los puntos forman una línea recta, son normales.

3 TEST ESTADÍSTICO

```
from scipy.stats import shapiro
stat, p_value = shapiro(df['col'])
```

- Ejecutá un test de normalidad (ej: Shapiro-Wilk).
- Interpretá el p-value:
 - $p\text{-value} < 0.05$: NO son normales (rechaza H_0).
 - $p\text{-value} > 0.05$: SON normales (no rechaza H_0).

Mirá tus datos: ¿se parecen a una normal?

Histograma + curva normal

Hacé un histograma y superponé la campana teórica que tendrían tus datos si fueran normales. Si pegan, son normales.

```
sns.histplot(datos, kde=True)
```

Veloz y visual. Lo primero que mirás.

Q-Q Plot

Compara tus datos con una normal teórica. Si forman una línea recta, son normales. Si se curvan, no.

```
stats.probplot(datos, plot=plt)
```

Más preciso, ideal para diagnóstico fino.

Las tres distribuciones en Python

```
from scipy import stats
import numpy as np


# Normal:  $P(X = x)$  y muestreo
stats.norm.pdf(1.5, loc=0, scale=1)      # densidad en  $x=1.5$ 
muestras = stats.norm.rvs(loc=170, scale=7, size=1000)

# Binomial: ¿prob de exactamente 6 caras en 10 tiradas?
stats.binom.pmf(k=6, n=10, p=0.5)        #  $\approx 0.205$ 
stats.binom.cdf(k=6, n=10, p=0.5)        #  $P(X \leq 6)$ 

# Poisson: ¿prob de 5 llamadas en 1h si  $\lambda=3$ ?
stats.poisson.pmf(k=5, mu=3)              #  $\approx 0.101$ 

# Test de normalidad Shapiro-Wilk
stat, pvalue = stats.shapiro(datos)
# si  $pvalue < 0.05 \rightarrow$  NO son normales
```

¿Cómo reconocer qué distribución usar?



Probate

1 Tirás una moneda 20 veces. ¿Cuántas caras esperarás obtener y qué distribución modela esto?

→ Esperás 10 caras. Es una binomial con $n=20$ y $p=0.5$.

2 Llegan al banco en promedio 4 clientes cada 15 minutos. ¿Qué distribución usás para modelar la cantidad de clientes en 15 min?

→ Poisson, con $\lambda=4$. Cuenta eventos en un intervalo fijo.

3 ¿Por qué decimos que la altura humana sigue una distribución normal?

→ Por el Teorema del Límite Central: es la suma de muchos factores chicos e independientes (genes, nutrición, etc.).

4 Mirás un histograma de salarios y se ve muy sesgado a la derecha (cola larga). ¿Es normal?

→ No. La distribución normal es simétrica. Los salarios suelen ser log-normales.