

UNIDAD 2 · CLASE 6

Estadística inferencial

Parámetros, intervalos de confianza y prueba de hipótesis

Modulo II · Ciencia de Datos e Introducción a Machine Learning

[Notebook](#) con ejemplos

Qué vamos a ver hoy

1

Población vs. muestra

Del total al subconjunto representativo

2

Estimación e intervalos

Puntual y por intervalo de confianza

3

Prueba de hipótesis

El método científico en estadística

4

Valor p y errores tipo I/II

La métrica clave y sus trampas

5

Test t de Student

Comparar medias con pocos datos

6

Por qué a ML le importa

A/B testing, validación y más

Lo que vimos en la Unidad 1

En la Unidad 1 describimos los datos: media, mediana, desvío, distribuciones, correlación.
Todo eso era ESTADÍSTICA DESCRIPTIVA: contar y resumir lo que ya tenemos.

Ahora la pregunta cambia:

DESCRIPTIVA


**¿Qué pasó con
ESTOS datos?**

INFERENCIAL

**¿Qué puedo concluir sobre
la POBLACIÓN entera?**

Estimación Puntual y por Intervalo

Proceso de inferencia: de la **Muestra** (datos conocidos) buscamos estimar el **Parámetro** de la **Población** (valor real desconocido). Hay dos formas de hacerlo.



Población ($\theta = ?$)

Muestra (θ)

1. Estimación Puntual

Un único valor numérico $\hat{\theta}$ obtenido de la estadística muestral.

$\hat{\theta}$

2. Estimación por Intervalo de confianza


Rango de valores ($\hat{\theta} - \text{error}$, $\hat{\theta} + \text{error}$) que contiene el parámetro con un nivel de confianza.

($\hat{\theta} \pm \text{Margen de Error}$)



Estimación Puntual: De la Muestra a la Población

El **muestreo** permite obtener una parte representativa de la **población** para inferir sus características desconocidas.



Estimadores	Parámetros	
Proporción muestral	$\hat{p}$	Proporción P
Media muestral	$\bar{x}$	Media μ
Cuasidesviación	s	Desviación σ

Ejemplo: A partir de la altura media de la muestra ($\bar{x}$), estimamos la altura media real de toda la población (μ).




Inferencia Estadística: Estatura en Argentina



Población



Muestra



La media de todas las medias muestrales es igual a la media poblacional (μ). Su distribución es una campana de Gauss más angosta que la original.

Estimación puntual vs. Intervalo de confianza

Objetivo: Estimar un parámetro desconocido de la población a partir de una muestra.

Característica	Estimación puntual	Intervalo de confianza
¿Qué proporciona?	Un único valor estimado	Un rango de valores plausibles
Resultado	Un número	Un intervalo
Incertidumbre	 No	 Sí
Ejemplo	$\bar{X} = 35$ años	IC 95%: (32,5 ; 37,5) años
Información	Mejor estimación del parámetro	Estimación y precisión

La estimación puntual indica un valor posible del parámetro, mientras que el intervalo de confianza expresa además la precisión de esa estimación.

Cálculo del Intervalo de Confianza para μ

El intervalo se construye sumando y restando un **margen de error** a la media muestral, definido por el valor crítico Z y el error estándar.

Conceptos clave

Nivel de confianza ($1 - \alpha$)


Probabilidad de que el intervalo contenga el valor real (ej. 95% o 99%).

Margen de error

Determina la precisión. A mayor confianza solicitada, el intervalo se vuelve más ancho (menos preciso).

Error Estándar

Mide la variabilidad de la media muestral respecto a la poblacional. Depende del tamaño de muestra n .




Representación de la Distribución Normal $N(\mu, \sigma/\sqrt{N})$

Intervalo de Confianza para μ

A partir de la media muestral ($\bar{x}$) generamos un rango de valores donde, con cierto nivel de seguridad, se encuentra la verdadera media poblacional (μ).

Componentes del IC

- **Media Muestral ($\bar{x}$):** El centro del intervalo.
- **Nivel de Confianza ($1-\alpha$):** Probabilidad de acierto (ej. 95%).
- **Margen de Error:** Determina la amplitud del intervalo según la variabilidad.



$$IC = \bar{x} \pm z_{\alpha/2} \cdot (\sigma / \sqrt{n})$$

Impacto del tamaño de muestra (N) en el Error

A medida que aumenta el tamaño de la muestra (N), el margen de error disminuye, resultando en un intervalo de confianza más preciso.

↓ ↓ error →

$$error = z_{\alpha/2} \cdot \sigma / \sqrt{N}$$

← N ↑ ↑

Muestra de N = 100



Muestra de N = 10.000



Ejercicio 1: Intervalo de Confianza

Calculamos el **IC al 90%** para el tiempo medio que los adultos dedican al deporte, basándonos en una muestra de 250 habitantes con una media muestral de 90 min.

Datos del Problema

Población: Dist. Normal $N(\mu, 20)$

Muestra (N): 250 habitantes

Media Muestral ($\bar{X}$): 90 min/día

Nivel de Confianza: 90% ($\alpha = 10\%$)


Valor Crítico ($z_{\alpha/2}$): 1,645

error = $1,645 \cdot (20 / \sqrt{250}) = 2,08$

IC = $(90 - 2,08 ; 90 + 2,08)$

Población $N(\mu, 20)$

Muestra $N = 250$ $\bar{X} = 90$ ¿IC_{90%} para μ ?



IC90% = (87,92 ; 92,08)


Cálculo del Valor Crítico ($z_{\alpha/2}$) y Error

Para un nivel de confianza del **95%**, buscamos el valor en la tabla de la normal que deja un área acumulada de **0,9750**.

Lectura de Tabla Normal Estándar

z	,00	,01	,02	,03	,04	,05	,06	,07	,08	,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177
1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9279	0,9292	0,9306	0,9319
1,5	0,9332	0,9345	0,9357	0,9370	0,9382	0,9394	0,9406	0,9418	0,9429	0,9441
1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545
1,7	0,9554	0,9564	0,9573	0,9582	0,9591	0,9599	0,9608	0,9616	0,9625	0,9633
1,8	0,9641	0,9649	0,9656	0,9664	0,9671	0,9678	0,9686	0,9693	0,9699	0,9706
1,9	0,9713	0,9719	0,9726	0,9732	0,9738	0,9744	0,9750	0,9756	0,976	0,9767
2,0	0,9772	0,9778	0,9783	0,9788	0,9793	0,9798	0,9803	0,9808	0,9812	0,9817

Distribución y Parámetros



$$z_{\alpha/2} = 1,9 + 0,06 = 1,96$$

Ejercicio 2: Cálculo del Tamaño de Muestra Mínimo

¿Qué tamaño mínimo debe tener una muestra aleatoria simple para que el error máximo cometido en la estimación de μ sea menor que 1 minuto (confianza del 90%)?

Planteamiento y Desarrollo

$$error \leq 1$$

$$z_{\alpha/2} \cdot (\sigma / \sqrt{N}) \leq 1$$

$$1,645 \cdot (20 / \sqrt{N}) \leq 1$$

$$1,645 \cdot (20 / 1) \leq \sqrt{N}$$

Resultado Final

$$32,9 \leq \sqrt{N}$$

$$32,9^2 \leq N$$

$$1082,41 \leq N$$

$$N = 1083 \text{ personas}$$

Resolución Automatizada con Python

Implementación de los cálculos de Intervalo de Confianza y Tamaño de Muestra Mínimo.

Ejercicio 1: Intervalo de Confianza

```
import scipy.stats as st
import numpy as np
# Datos del problema
n, media, sigma = 250, 90, 20
confianza = 0.90
# Cálculo del Valor Crítico
z = st.norm.ppf((1 + confianza) / 2)
# Error y Límites
error = z * (sigma / np.sqrt(n))
lim_inf = media - error
lim_sup = media + error
print(f"IC: ({lim_inf:.2f}, {lim_sup:.2f})")
```

Ejercicio 2: Tamaño de Muestra

```
import scipy.stats as st
import math
# Datos: Error < 1 min, Confianza 90%
error_max = 1
sigma = 20
confianza = 0.90
# Valor Crítico z
z = st.norm.ppf((1 + confianza) / 2)
# Despeje de N
n_min = (z * sigma / error_max)**2
# Redondear al entero superior
n_final = math.ceil(n_min)
print(f"N mínimo: {n_final} personas")
```

El método científico en estadística

Una prueba de hipótesis evalúa si los datos aportan evidencia suficiente para rechazar una suposición inicial (la hipótesis nula).

Ejemplo: un juicio penal

1

Suposición inicial

"El acusado es inocente" (hipótesis nula H_0).
Es lo que asumimos hasta probar lo contrario.

2

Evidencia

Se presentan pruebas (datos). El fiscal intenta mostrar que H_0 no puede ser verdad.

3

Decisión

Si la evidencia es suficientemente fuerte, se rechaza H_0 y se declara culpable.
Si no, no se rechaza H_0 (no es lo mismo que declararla cierta).

H_0 y H_1 : Definición de términos

H_0 · Hipótesis Nula

Definición

Es el punto de partida o estado por defecto. Plantea que no hay cambios, efectos o diferencias significativas.

Ejemplo

"El nuevo tratamiento no mejora el resultado."

$$H_0: \mu_1 = \mu_2$$

H_1 · Hipótesis Alternativa

Lo que buscamos probar

Sostiene que existe un efecto, relación o diferencia real entre los grupos estudiados.

Ejemplo

"El tratamiento sí mejora el resultado."

$$H_1: \mu_1 \neq \mu_2 \quad (\text{Bilateral})$$

$$H_1: \mu_1 > \mu_2 \quad (\text{Unilateral})$$



Importante: Nunca "aceptamos" H_0 . Solo decidimos si hay evidencia suficiente para RECHAZARLA o no.

El p-valor: qué es y cómo leerlo

El p-valor es la probabilidad de obtener un resultado tan extremo como el observado (o más), SUPONIENDO que H_0 es verdadera.

No es la probabilidad de que H_0 sea verdadera. Es la probabilidad de los datos dado H_0 .

Cómo interpretar el p-valor

$$p < 0.01$$

Evidencia muy fuerte
para rechazar H_0

$$0.01 \leq p < 0.05$$

Evidencia suficiente
(nivel $\alpha = 0.05$ habitual)

$$0.05 \leq p < 0.10$$

Evidencia débil.
Hablar con cautela

$$p \geq 0.10$$

Sin evidencia para
rechazar H_0

Convención habitual: $\alpha = 0.05$. Si $p < \alpha \rightarrow$ rechazamos H_0 . Si $p \geq \alpha \rightarrow$ no la rechazamos.

El nivel α es la probabilidad máxima de Error Tipo I que estamos dispuestos a tolerar.

Error tipo I y error tipo II

Tomar una decisión a partir de datos nunca es 100% seguro. Existen dos tipos de errores posibles en el contraste de hipótesis.

	H_0 es VERDADERA	H_0 es FALSA
No rechazamos H_0	✓ Decisión correcta (Confianza = $1 - \alpha$)	Error tipo II (β) "Falso negativo" Hay efecto pero no lo vemos
Rechazamos H_0	Error tipo I (α) "Falso positivo" No hay efecto pero creemos que sí	✓ Decisión correcta (Potencia = $1 - \beta$)

Supuestos de las pruebas paramétricas

Normalidad

Los datos deben seguir una distribución normal. Se verifica con el test de Shapiro-Wilk o histogramas.

Homocedasticidad

Igualdad de varianzas entre grupos. Crucial para Test t y ANOVA. Se evalúa con el test de Levene.

Independencia

Las observaciones deben ser independientes entre sí. Es el supuesto más crítico del diseño experimental.

¿Qué pasa si no se cumplen?

Si los supuestos fallan, los resultados del p-valor pierden validez. En ese caso, se deben usar pruebas no paramétricas (como Wilcoxon o Kruskal-Wallis).

Test t de Student: comparar medias

El test t evalúa si la media de una muestra (o la diferencia entre dos medias) es estadísticamente significativa. Es ideal para muestras pequeñas ($n < 30$).

t de una muestra

¿La media de mi muestra es igual a un valor de referencia?

$$H_0: \mu = \mu_0$$

Ejemplo: ¿La nota promedio del curso ($\bar{X} = 6.8$) es igual a 7?

t de muestras independientes

¿Las medias de DOS grupos distintos son iguales?

$$H_0: \mu_1 = \mu_2$$

Ejemplo: ¿El grupo A y el grupo B tienen igual promedio?

t pareada

¿Cambió la media del MISMO grupo antes y después?

$$H_0: \mu_{\text{diff}} = 0$$

Ejemplo: ¿Mejoró el puntaje tras el entrenamiento?

Test Chi-cuadrado: variables categóricas

Evalúa si existe una asociación significativa entre dos variables categóricas o si una distribución observada se ajusta a una teórica. Se basa en comparar frecuencias observadas vs. esperadas.

Test de Independencia

¿Están relacionadas dos variables cualitativas? (Ej: Género y preferencia de producto)

H_0 : Las variables son independientes.

Ejemplo: ¿La zona de residencia influye en la elección del plan de suscripción?

Bondad de Ajuste

¿Se ajustan los datos observados a una distribución esperada?

H_0 : Los datos siguen la distribución teórica.

Ejemplo: ¿Un dado está equilibrado (todas las caras salen con frecuencia $1/6$)?

Test Chi-cuadrado en Python

```
from scipy.stats import chi2_contingency

# 1. Definir tabla de contingencia (ej: Género vs Compra)
data = [[20, 30], [35, 15]]
# Fila 1: Hombres (Compran/No), Fila 2: Mujeres

# 2. Ejecutar test de independencia
stat, p, dof, expected = chi2_contingency(data)

print(f"Estadístico: {stat:.4f}")
print(f"P-valor: {p:.4f}")

if p < 0.05:
    # Rechazamos H0
    print("Hay una asociación significativa entre las variables")
else:
    # No rechazamos H0
    print("Las variables son independientes")
```

ANOVA: comparar tres o más grupos

El ANOVA (Análisis de Varianza) evalúa si al menos una media difiere entre tres o más grupos. Es la generalización natural del test t cuando hay más de dos grupos para comparar.

¿Por qué no usar varios test t?

Comparar A-B, A-C y B-C de a pares infla el error tipo I acumulado.

α acumulado > 0.05

Ejemplo: con 3 grupos, 3 test t por separado ya superan el 5% de error global.

Hipótesis del ANOVA

¿Las medias de tres o más grupos son todas iguales?

$H_0: \mu_1 = \mu_2 = \mu_3$

Ejemplo: ¿el grupo A, el B y el C tienen igual promedio?

Si se rechaza H_0

El ANOVA dice que HAY diferencia, pero no entre cuáles grupos.

Post-hoc: Tukey HSD

Ejemplo: comparar 3 algoritmos de ML por su métrica de validación.

Cuando no se cumple la normalidad

Si el supuesto de normalidad falla (Shapiro-Wilk con $p < 0.05$), el test t y el ANOVA pierden validez. Estas pruebas comparan los rangos de los datos en lugar de sus medias.

Mann-Whitney U

¿Dos grupos independientes tienen la misma distribución?

Equivale a: `ttest_ind`

Ejemplo: ¿dos tratamientos difieren si los datos no son normales?

Kruskal-Wallis

¿Tres o más grupos tienen la misma distribución?

Equivale a: `f_oneway`

Ejemplo: ¿A, B y C tienen la misma distribución sin normalidad?

Regla práctica

Si falla Shapiro-Wilk, reemplazá el test paramétrico por su par no paramétrico.

2 grupos → `mannwhitneyu`

3+ grupos → `kruskal`

Por qué la estadística inferencial importa en Machine Learning

A/B Testing

Comparar dos versiones de un modelo, interfaz o algoritmo. ¿El modelo B es realmente mejor que el A? Se usa un test de hipótesis (a menudo t-test o chi-cuadrado) para saberlo con rigor estadístico.

Validación cruzada (cross-validation)

Cada fold produce una métrica. El promedio de esas métricas es una estimación puntual del rendimiento real del modelo. El desvío estándar entre folds construye un intervalo de confianza del rendimiento.

Selección de features

Tests estadísticos (chi-cuadrado, ANOVA, test t) ayudan a decidir si una variable tiene relación estadísticamente significativa con el target, antes de incluirla en el modelo.

Intervalos de predicción

Regresión lineal no sólo da un punto predicho sino un intervalo de confianza alrededor. Eso comunica la incertidumbre del modelo, algo crítico en aplicaciones médicas o financieras.

Estadística inferencial en Python

```
from scipy import stats

# 1. Validar normalidad (Shapiro-Wilk)
# Si p > 0.05, los datos son normales
stat, p_norm = stats.shapiro(muestra)

if p_norm > 0.05:
    # Si es normal, usamos test paramétrico
    stat, pvalue = stats.ttest_1samp(muestra, popmean=7.0)
else:
    # Si no, alternativa no paramétrica
    stat, pvalue = stats.wilcoxon(muestra - 7.0)
```

Estadística inferencial en Python

```
from scipy import stats
import numpy as np

# Intervalo de confianza (95%) para la media
muestra = df['nota'].dropna()
ic = stats.t.interval(0.95, df=len(muestra)-1,
                     loc=muestra.mean(), scale=stats.sem(muestra))
print(f'IC 95%: {ic}')    # (6.51, 7.49)

# Test t: ¿la nota media es igual a 7.0?
stat, pvalue = stats.ttest_1samp(muestra, popmean=7.0)
# si pvalue < 0.05 → rechazamos H0

# Test t: ¿grupos A y B tienen la misma media?
stat, pvalue = stats.ttest_ind(grupo_a, grupo_b)
```

Cuándo usar qué herramienta

Herramienta	¿Cuándo usarla?	Ejemplo típico	Función Python
Estimación puntual	Necesito un único valor estimado	Estimar μ con $\bar{X}$	<code>df.mean()</code>
Intervalo de confianza	Quiero cuantificar incertidumbre	IC del 95% para μ	<code>stats.t.interval()</code>
Test t (1 muestra)	Comparar una media con valor teórico	¿ $\mu = 7$?	<code>ttest_1samp()</code>
Test t (2 muestras)	Comparar dos grupos independientes	¿Grupo A = Grupo B?	<code>ttest_ind()</code>
Test t pareado	Comparar medidas antes/después	¿Mejoró con el tratamiento?	<code>ttest_rel()</code>
ANOVA	Comparar tres o más grupos	¿Medias A=B=C?	<code>f_oneway()</code>
Mann–Whitney U	2 grupos indep. sin normalidad	¿Dos tratamientos difieren?	<code>mannwhitneyu()</code>
Kruskal–Wallis	3+ grupos sin normalidad	¿Misma distribución?	<code>kruskal()</code>
Chi-cuadrado	Variables categóricas	¿Género influye en pref.?	<code>chi2_contingency()</code>

Probate

1

Una encuesta de 200 personas revela que $\bar{X} = 4.8$ horas de sueño. ¿Es eso una estimación puntual o un intervalo de confianza?

→ Estimación puntual: es un único número. Para construir un intervalo necesitaríamos el desvío estándar y el nivel de confianza deseado.

2

Un test t devuelve $p = 0.032$ con $\alpha = 0.05$. ¿Rechazamos H_0 ?

→ Sí. Como $p(0.032) < \alpha(0.05)$, hay evidencia suficiente para rechazar la hipótesis nula.

3

Un médico prueba una nueva droga y concluye que funciona cuando en realidad no funciona. ¿Qué tipo de error cometió?

→ Error tipo I (falso positivo): rechazó H_0 siendo verdadera. La probabilidad de este error es α .

4

Querés comparar el rendimiento de dos modelos de ML entrenados en datasets independientes. ¿Qué test usarías?

→ Test t de muestras independientes (ttest_ind), usando las métricas de cada fold de validación cruzada como observaciones.